Post-training of Language Models

Hà Thanh Phong – 24520024
Hà Xuân Thiện – 24520031
Trần Quang Trường – 24521901

University of Information Technology – VNUHCM

Ngày 29 tháng 10 năm 2026

Mục lục chuyên đề

Lộ trình bốn giai đoạn tiến hóa của Post-training (2020–2026).

1. **01 Supervised Fine-Tuning (SFT):** Từ dự đoán văn bản đến tuân thủ chỉ thị và Loss Masking.
2. **02 Alignment với RLHF và PPO:** Học từ cặp đối chiếu, Reward Model và kiểm soát bằng KL penalty.
3. **03 Direct Preference Optimization (DPO):** Closed-form solution và tối ưu trực tiếp không cần mạng Critic.
4. **04 RLVR và GRPO:** Thưởng kiểm chứng khách quan, chuẩn hóa nhóm và sự nảy sinh tư duy suy luận.

PHẦN 1 / 04

Supervised Fine-Tuning (SFT)

2020–2021

Nội dung: Base Model, mục tiêu chỉ thị, dữ liệu và SFT Loss.

Mục tiêu dự đoán token tiếp theo của Base Model.

Mục tiêu dự đoán token tiếp theo

$$\mathcal{L}_{\text{Pretrain}}(\theta) = -\sum_{t=1}^{T} \log P_\theta(u_t \mid u_1, u_2, \ldots, u_{t-1})$$

Base Model học được gì?

- **Xấp xỉ phân phối biên ngôn ngữ:** Học phân phối có điều kiện $P_\theta(u_t \mid u_{<t})$.
- **Nội hóa tri thức thế giới:** Nén cú pháp, tri thức sự kiện (factual knowledge) và quy luật suy diễn.

Mục tiêu của Post-training

Định hướng phân phối phản hồi: Chuyển dịch từ $P_\theta(u_t \mid u_{<t})$ sang phân phối phản hồi theo chỉ thị $\pi_\theta(y \mid x)$.

Ba tiêu chuẩn căn chỉnh (3H Criteria):

1. **Helpful (Hữu ích):** Giải quyết đúng yêu cầu.
2. **Honest (Trung thực):** Hạn chế bịa đặt thông tin.
3. **Harmless (Vô hại):** Từ chối tác vụ độc hại.

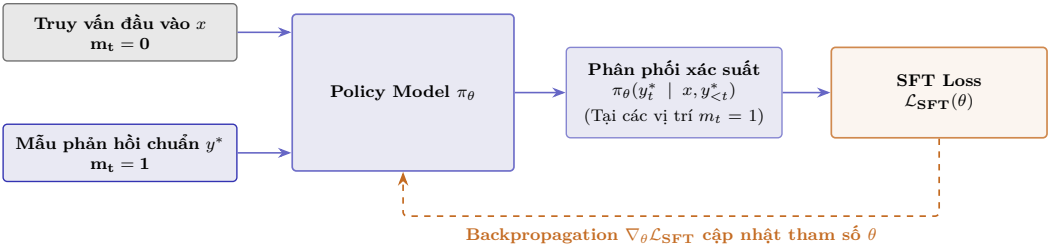
Dữ liệu SFT và khuôn mẫu hội thoại

SFT học bắt chước phản hồi của chuyên gia (Wei et al., 2022).

Dữ liệu và Control Tokens

- **Tập dữ liệu:** $\mathcal{D}_{\text{SFT}} = \{(x^{(i)}, y^{*(i)})\}_{i=1}^{N}$ gồm truy vấn đầu vào x và mẫu phản hồi chuẩn y^*.
- **Phân vùng ngữ cảnh bằng Control Tokens:**
  - `<|im_start|>system ... <|im_end|>` $\longrightarrow$ Ràng buộc hệ thống toàn cục.
  - `<|im_start|>user ... <|im_end|>` $\longrightarrow$ Miền truy vấn đầu vào x.
  - `<|im_start|>assistant ... <|im_end|>` $\longrightarrow$ Miền sinh phản hồi mục tiêu y^*.

SFT: luồng dữ liệu và Loss Masking



Quy trình huấn luyện SFT với Loss Masking.

Conditional Maximum Likelihood Estimation (MLE).

SFT Loss (Conditional MLE)

$$\mathcal{L}_{\mathrm{SFT}}(\theta) = -\,\mathbb{E}_{(x,y^*)\sim\mathcal{D}_{\mathrm{SFT}}}\left[\sum_{t=1}^{|y^*|}\log \pi_\theta\big(y_t^* \mid x, y_1^*, \ldots, y_{t-1}^*\big)\right]$$

Ý nghĩa các ký hiệu trong công thức

- θ, π_θ: Tham số cần tối ưu và mô hình chính sách.
- $\mathcal{D}_{\mathrm{SFT}}$: Tập dữ liệu gồm các cặp prompt–phản hồi (x, y^*).
- $y^*_{<t}$: Ngữ cảnh tiền tố $y_1^*, \ldots, y_{t-1}^*$.

Chất lượng dữ liệu: Giả thuyết LIMA

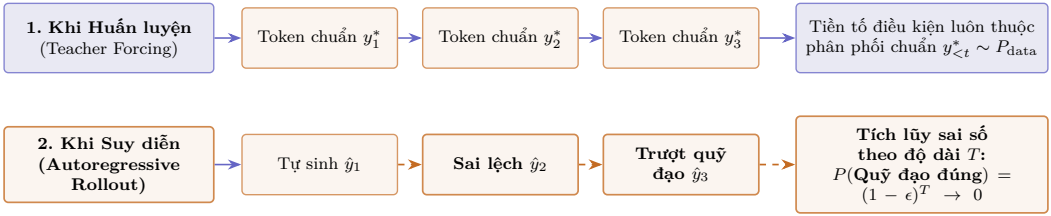
Zhou et al., 2023 – Less Is More for Alignment (LIMA).

Superficial Alignment Hypothesis

- **Tri thức từ Pre-training:** Toàn bộ tri thức thế giới và năng lực suy luận đã được tiếp thu ở giai đoạn Pre-training.
- **Bản chất của SFT:** SFT chỉ đóng vai trò học phong cách (style), định dạng hội thoại và phong thái trợ lý.
- **Không tạo tri thức mới:** SFT không nạp thêm kiến thức mới mà chỉ kích hoạt tri thức sẵn có theo chỉ thị.

SFT: huấn luyện và suy diễn

Teacher forcing dùng tiền tố chuẩn; Autoregressive Decoding dùng tiền tố tự sinh.



Khi huấn luyện: $s_t = (x, y^*_{<t}) \sim P_{\text{data}}$. Khi suy diễn: $\hat{s}_t = (x, \hat{y}_{<t}) \sim \pi_\theta$.
Với $\epsilon = 0.01$, $T = 200$, xác suất giữ đúng quỹ đạo giảm còn $(0.99)^{200} \approx 13.4\%$.

Hạn chế của SFT

1. **Exposure Bias:**
   Mô hình chỉ quan sát tiền tố mẫu $y^*_{<t} \sim P_{\text{data}}$, chưa bao giờ được huấn luyện trên chuỗi tự sinh $\hat{y} \sim \pi_\theta$.
2. **Extrinsic Hallucination:**
   Cực đại hóa $\log \pi_\theta(y^* \mid x)$ trên cả tri thức nằm ngoài Base Model khiến mô hình suy giảm hiệu chỉnh xác suất (Miscalibration) và sinh thông tin bịa đặt.
3. **Absence of Negative Samples:**
   SFT chỉ gia tăng xác suất cho mẫu dương chuẩn y^* ($\uparrow$), không có gradient phạt ($\downarrow$) đối với các mẫu âm sai lệch y_l.

PHẦN 2 / 04

Alignment với RLHF và PPO

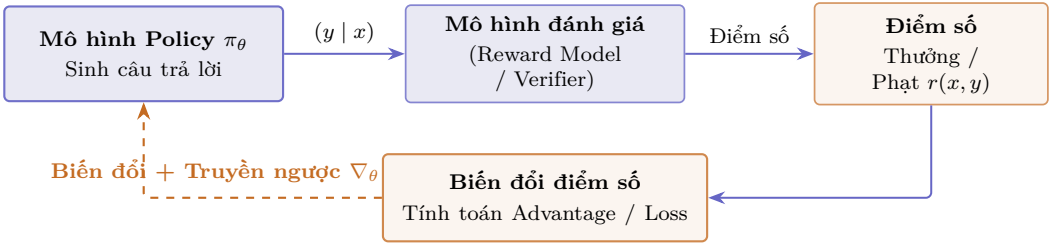
2022–đầu 2023

Nội dung: Sở thích cặp, Reward Model, KL regularization và kiến trúc bốn mạng.

Học tăng cường (RL): đánh giá câu trả lời của mô hình

Chu trình phản hồi đóng: sinh câu trả lời, định giá và tối ưu hóa chính sách.

Bức tranh tổng thể



- **Đánh giá chuỗi toàn diện:** Khắc phục hạn chế của SFT (chỉ học từng token), mô hình đánh giá chấm điểm trên toàn bộ câu trả lời $y \sim \pi_\theta$.
- **Tối ưu hóa khép kín:** Điểm số được biến đổi và lan truyền ngược để cập nhật tham số θ, tăng xác suất phản hồi tốt và giảm phản hồi kém.

Mô hình Phần thưởng (Reward Model)

Thước đo tự động hóa sở thích và tiêu chuẩn đánh giá của con người.

Cấu trúc và cơ chế hoạt động

- **Đầu vào (Input):** Cặp gồm câu truy vấn x và câu trả lời hoàn chỉnh y.
- **Đầu ra (Output):** Điểm số vô hướng $r_\phi(x, y) \in \mathbb{R}$ phản ánh độ chính xác và mức ưa thích.
- **Vai trò cốt lõi:**
  Đóng vai trò hàm mục tiêu tự động (Automated Proxy), thay thế con người liên tục chấm điểm cho hàng triệu phản hồi trong quá trình huấn luyện RL.

Quy trình xây dựng tập $\mathcal{D}_{\text{pair}}$

- **Lấy mẫu cặp phản hồi:** Truy vấn $x \sim \mathcal{D}_{\text{prompt}}$, sinh cặp đầu ra $(y_1, y_2) \sim \pi_{\text{SFT}}(\cdot \mid x)$.
- **Gán nhãn ưu tiên (Pairwise Comparison):** Chuyên gia chọn $y_w \succ y_l$.
  - y_w (Preferred / Mẫu dương): Phản hồi hữu ích, an toàn hơn.
  - y_l (Dispreferred / Mẫu âm): Phản hồi lỗi, độc hại hoặc lạc đề.

Tại sao sử dụng so sánh cặp?

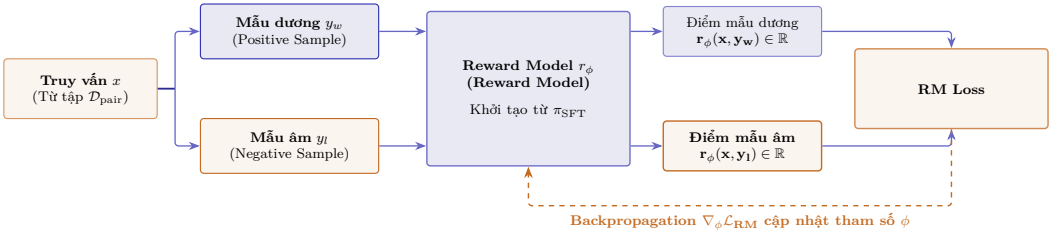
Loại bỏ phương sai cá nhân và trôi ngưỡng chấm điểm tuyệt đối.

Ưu thế thống kê của quan hệ nhị phân

- **Hạn chế của thang điểm tuyệt đối** (1–10)**:**
  Phương sai cao giữa các chuyên gia.
- **Tính nhất quán của so sánh nhị phân** ($y_w \succ y_l$)**:**
  Độ đồng thuận thống kê cao.
- **Bổ sung Mẫu âm** y_l **(Negative Sample):**
  Cung cấp ranh giới đối chiếu rõ ràng để triệt tiêu hành vi sai lệch.

Huấn luyện Reward Model

Học điểm vô hướng $r_\phi(x, y) \in \mathbb{R}$ từ cặp mẫu dương và mẫu âm.



Maximum Likelihood Estimation cho quan hệ thứ tự cặp.

$$P(y_w \succ y_l \mid x) = \sigma\big(r_\phi(x, y_w) - r_\phi(x, y_l)\big), \qquad \mathcal{L}_{\text{RM}}(\phi) = -\,\mathbb{E}_{(x, y_w, y_l)}\Big[\log \sigma\big(r_\phi(x, y_w) - r_\phi(x, y_l)\big)\Big]$$

Nguyên lý: Cặp (x, y_w) và (x, y_l) cùng đi qua r_ϕ; gradient kéo tăng $r_\phi(x, y_w)$ ($\uparrow$) và hạ thấp $r_\phi(x, y_l)$ ($\downarrow$).

Rủi ro khi tối ưu trực tiếp $r_\phi(x, y)$

- **Định luật Goodhart:** Thước đo trở thành mục tiêu tối ưu sẽ mất tính tin cậy.
- **Sai số ngoài phân phối (OOD Error):**
  r_ϕ chỉ tin cậy gần π_{SFT}; ra xa vùng huấn luyện, r_ϕ cho điểm cao giả tạo.
- **Hiện tượng Reward Hacking:**
  Policy sinh văn bản vô nghĩa hoặc lặp từ nhưng vẫn đạt r_ϕ cực đại.

$\Longrightarrow$ **Cần giữ phân phối Policy không đi quá xa khỏi phân phối mô hình sau khi SFT.**

Điều chuẩn vùng tin cậy bằng KL Divergence

Neo giữ Policy trong vùng tin cậy của mô hình tham chiếu π_{ref}.

Khoảng cách KL phân phối có điều kiện

$$\mathrm{D}_{\mathrm{KL}}\left(\pi_\theta(\cdot \mid x) \,\|\, \pi_{\text{ref}}(\cdot \mid x)\right) = \mathbb{E}_{y\sim\pi_\theta}\left[\log \frac{\pi_\theta(y \mid x)}{\pi_{\text{ref}}(y \mid x)}\right]$$

Ý nghĩa của khoảng cách D_{KL}

- $\mathrm{D}_{\mathrm{KL}} \to 0$: Phân phối của Policy trùng khớp hoàn toàn với mô hình sau SFT.
- $\mathrm{D}_{\mathrm{KL}} \to \infty$: Phân phối Policy trôi dạt quá xa, có nguy cơ suy biến do Reward Hacking.

Tối đa hóa phần thưởng kết hợp KL regularization (Ouyang et al., 2022).

Mục tiêu RLHF có điều chuẩn KL

$$\max_{\pi_\theta} \; J_{\text{RLHF}}(\pi_\theta) = \mathbb{E}_{x\sim\mathcal{D},\, y\sim\pi_\theta}\left[r_\phi(x,y) - \beta \log \frac{\pi_\theta(y \mid x)}{\pi_{\text{ref}}(y \mid x)}\right]$$

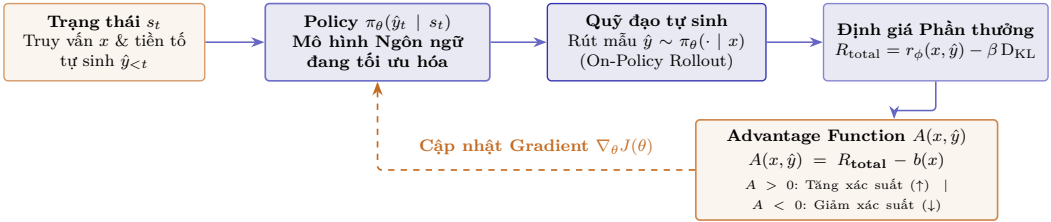
Policy Gradient với Advantage $A(x,y)$

$$\nabla_\theta J(\theta) = \mathbb{E}_{y\sim\pi_\theta}\Big[\underbrace{\big(R_{\text{total}}(x,y) - b(x)\big)}_{\text{Advantage } A(x,y)} \nabla_\theta \log \pi_\theta(y \mid x)\Big]$$

Ý nghĩa của Baseline $b(x)$ và Advantage $A(x,y)$

- **Baseline $b(x)$:** Điểm trung bình cho prompt x.
- **Advantage $A(x,y)$:** ($A > 0$: tăng xác suất ↑; $A < 0$: ghìm xác suất ↓).

Policy tự sinh mẫu $\hat{y} \sim \pi_\theta$ rồi nhận phản hồi để cập nhật.



Khắc phục Exposure Bias: Policy được tối ưu trực tiếp trên trạng thái tự sinh $\hat{s}_t \sim \pi_\theta$ và nhận phạt âm ($A < 0$) ngay khi đi chệch quỹ đạo.

Giải quyết bất ổn định do biến động phần thưởng trong huấn luyện RL.

Động lực ra đời

- **Bất ổn định do bùng nổ reward:**
  Điểm thưởng $R(x, y)$ có phương sai rất lớn giữa các câu trả lời, làm gradient dao động mạnh và dễ gây sụp đổ chính sách.
- $\Longrightarrow$ **Cần mạng Critic (V_ψ):**
  Cần một mạng đo trước điểm số kỳ vọng sẽ nhận được từ trạng thái hiện tại để làm mốc quy chiếu (baseline).

Ước lượng reward tại từng vị trí token.

Cấu trúc

- **Đầu vào (Input):** Trạng thái $s_t = (x, y_{<t})$ gồm prompt x và tiền tố chuỗi tự sinh $y_{<t}$.
- **Đầu ra (Output):** Điểm số kỳ vọng vô hướng $V_\psi(s_t) \in \mathbb{R}$.

Hàm mất mát của Value Network V_ψ

$$\hat{A}_t = R_t - V_\psi(s_t), \qquad \mathcal{L}_{\text{Critic}}(\psi) = \mathbb{E}_t \left[\left(R_t - V_\psi(s_t) \right)^2 \right]$$

Vai trò

- **Token-level Baseline:** Dự báo phần thưởng kỳ vọng từ trạng thái s_t, giảm mạnh phương sai của $\hat{A}_t$.

Thuật toán PPO: cơ chế Clipping

Giới hạn tỷ số xác suất để cập nhật ổn định trong vùng tin cậy (Schulman et al., 2017).

Hàm mục tiêu PPO-Clip

$$\mathcal{J}_{\text{PPO}}(\theta) = \mathbb{E}_t \left[\min \left(\rho_t(\theta)\hat{A}_t,\ \text{clip}\left(\rho_t(\theta), 1-\epsilon, 1+\epsilon\right)\hat{A}_t \right) \right]$$

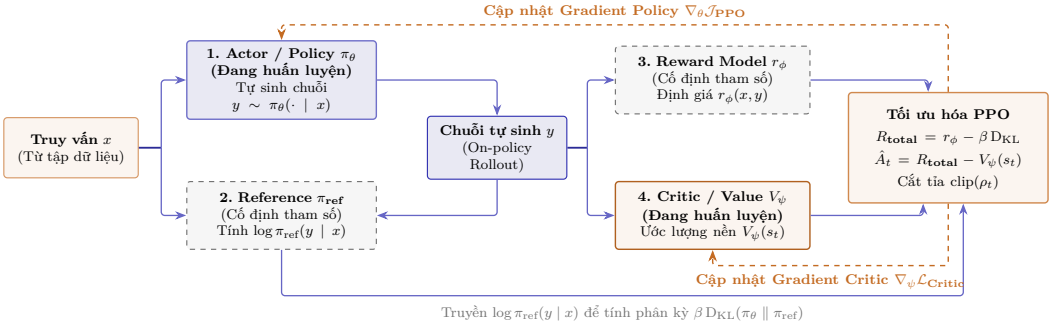
với tỷ số xác suất: $\rho_t(\theta) = \dfrac{\pi_\theta(y_t \mid x, y_{<t})}{\pi_{\theta_{\text{old}}}(y_t \mid x, y_{<t})}$.

Cơ chế chặn gradient

- $\rho_t(\theta)$: Tỷ số đo lường mức thay đổi xác suất giữa chính sách mới và cũ.
- Khi $\rho_t(\theta)$ vượt ngoài $[1-\epsilon, 1+\epsilon]$ ($\epsilon = 0.2$), gradient bị triệt tiêu về 0.
- Ngăn ngừa các bước cập nhật quá lớn làm sụp đổ chính sách.

RLHF + PPO: bốn mô hình phối hợp

Actor, Reference, Reward Model và Critic cùng hoạt động trên GPU.



Hạn chế của RLHF + PPO

1. **4-Model Memory Bottleneck:**
   Duy trì đồng thời bốn mạng $(\pi_\theta, \pi_{\text{ref}}, r_\phi, V_\psi)$ trên GPU.
2. **Autoregressive Rollout Bottleneck:**
   Sinh mẫu tự hồi quy từng token của mô hình Policy.
3. **Variance and Approximation Error:**
   Sai số xấp xỉ từ r_ϕ và Critic V_ψ khiến gradient có phương sai lớn và bất ổn định.

PHẦN 3 / 04

Direct Preference Optimization (DPO)

2023–2024

Nội dung: Closed-form solution, gradient và kiến trúc hai mô hình.

Bài toán có điều chuẩn KL và nghiệm giải tích Gibbs–Boltzmann.

Nghiệm cực trị Gibbs–Boltzmann

Xét bài toán cực trị có ràng buộc phân kỳ KL:

$$\max_{\pi} \mathbb{E}_{x,\, y\sim\pi}\left[r(x,y) - \beta \log \frac{\pi(y \mid x)}{\pi_{\text{ref}}(y \mid x)}\right] \implies \pi^*(y \mid x) = \frac{1}{Z(x)}\pi_{\text{ref}}(y \mid x)\exp\left(\frac{1}{\beta}r(x,y)\right)$$

Hàm thưởng ngầm định (Implicit Reward)

Nghịch đảo phương trình Gibbs để biểu diễn hàm thưởng theo Policy:

$$\boxed{r(x,y) = \beta \log \frac{\pi^*(y \mid x)}{\pi_{\text{ref}}(y \mid x)} + \beta \log Z(x)}$$

với $Z(x) = \sum_y \pi_{\text{ref}}(y \mid x)\exp\left(\frac{1}{\beta}r(x,y)\right)$ là hàm phân định.

Khử $Z(x)$ qua hiệu số reward

Khi lấy hiệu số giữa mẫu dương y_w và mẫu âm y_l, $\beta \log Z(x)$ **tự triệt tiêu**:

$$r(x, y_w) - r(x, y_l) = \beta \log \frac{\pi^*(y_w \mid x)}{\pi_{\text{ref}}(y_w \mid x)} - \beta \log \frac{\pi^*(y_l \mid x)}{\pi_{\text{ref}}(y_l \mid x)}$$

DPO Loss

$$\mathcal{L}_{\text{DPO}}(\theta) = -\,\mathbb{E}_{(x, y_w, y_l)} \left[\log \sigma \left(\beta \log \frac{\pi_\theta(y_w \mid x)}{\pi_{\text{ref}}(y_w \mid x)} - \beta \log \frac{\pi_\theta(y_l \mid x)}{\pi_{\text{ref}}(y_l \mid x)} \right) \right]$$

Tự điều chỉnh biên độ cập nhật giữa mẫu dương y_w và mẫu âm y_l.

Đạo hàm gradient đầy đủ (Rafailov et al., 2023)

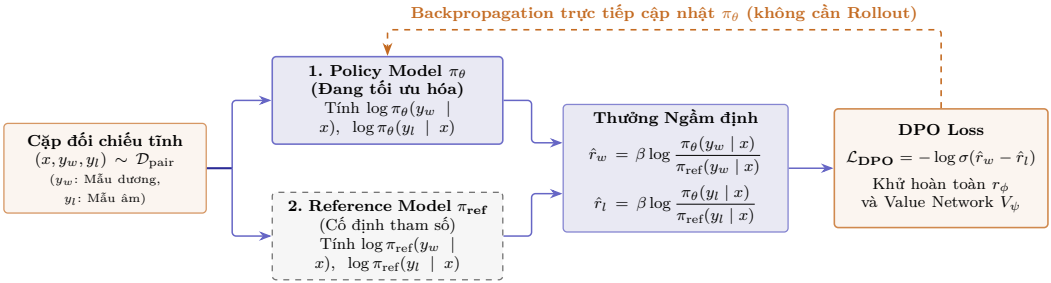
$$\nabla_\theta \mathcal{L}_{\text{DPO}}(\theta) = -\beta\, \mathbb{E}\Big[\underbrace{\sigma\big(\hat{r}_\theta(x, y_l) - \hat{r}_\theta(x, y_w)\big)}_{\text{Trọng số lỗi } \in (0,1)} \cdot \Big(\underbrace{\nabla_\theta \log \pi_\theta(y_w \mid x)}_{\text{Kéo Mẫu dương } (\uparrow)} - \underbrace{\nabla_\theta \log \pi_\theta(y_l \mid x)}_{\text{Đẩy Mẫu âm } (\downarrow)}\Big)\Big]$$

Cơ chế tự điều trọng số động

- **Khi xếp hạng sai ($\hat{r}_l > \hat{r}_w$):** Hệ số lỗi $\to 1.0 \implies$ Tăng mạnh gradient để sửa sai.
- **Khi phân loại đúng ($\hat{r}_w \gg \hat{r}_l$):** Hệ số lỗi $\to 0 \implies$ Triệt tiêu gradient, chống quá khớp.
- **Tác động đối ngẫu:** Đồng thời tăng $\pi_\theta(y_w)$ ($\uparrow$) và hạ thấp $\pi_\theta(y_l)$ ($\downarrow$).

DPO: kiến trúc hai mô hình

Chỉ giữ Policy π_θ và Reference Model π_{ref} trên GPU.



Ưu thế hệ thống: Tính toán log-xác suất song song trên toàn chuỗi (y_w, y_l) trong một forward pass duy nhất.

Hạn chế của DPO trong bài toán suy luận

1. **Off-policy Exploration Bottleneck:**
   Chỉ học thụ động trên tập cặp tĩnh $\mathcal{D}_{\text{pair}}$, không tự khám phá quỹ đạo suy luận mới.
2. **Reward Hacking trên bài toán hình thức:**
   Trong toán và code, mô hình dễ sa vào các lời giải ngụy biện nhưng trình bày đẹp mắt.
3. **Không kích hoạt Test-time Scaling:**
   Không thúc đẩy mô hình mở rộng chuỗi suy nghĩ CoT dài để tự giải quyết bài toán phức tạp.

PHẦN 4 / 04

RLVR và GRPO

Cuối 2024–2026

Nội dung: Kiểm chứng kết quả, chuẩn hóa nhóm và học suy luận.

Bốn giai đoạn của Post-training: từ SFT đến GRPO / RLVR

Giới hạn của Reward Model trong suy luận logic

Mô hình định giá xấp xỉ r_ϕ thất bại trước các bài toán toán học và lập trình.

- **Thiên kiến bề mặt:** Chấm điểm cao cho lời giải hoa mỹ dù kết quả sai hoặc ngụy biện.
- **Reward Hacking:** Policy sinh lập luận giả tạo để tối đa hóa điểm số của r_ϕ.
- **Cần tính tất định:** Miền Toán và Code đòi hỏi bộ thẩm định khách quan, chính xác tuyệt đối.

Đánh giá dựa trên tính đúng đắn của kết quả qua bộ kiểm chứng khách quan.

Hàm thưởng nhị phân tất định (Lambert et al., 2024)

$$R_{\text{RLVR}}(x, y) = \begin{cases} 1 & \text{nếu Verify}(\text{ExtractAnswer}(y),\ y_{\text{gold}}) = \text{True} \\ 0 & \text{trong mọi trường hợp còn lại} \end{cases}$$

Đặc tính của bộ kiểm chứng tất định

- **Toán học:** Trích xuất đáp số trong `\boxed{}`, đối sánh tương đương đại số.
- **Lập trình:** Biên dịch và thực thi bộ kiểm thử (Unit Tests trong Sandbox).
- **Zero OOD Degradation:** Triệt tiêu reward hacking, duy trì RL ổn định hàng vạn bước.

Credit Assignment: ORM và PRM

Phân bổ tín hiệu thưởng trên chuỗi suy luận nhiều bước $y = (s_1, s_2, \ldots, s_K)$.

- **Outcome Reward Model (ORM):**
  Cấp một điểm thưởng $R \in \{0, 1\}$ tại cuối chuỗi. Tương thích bộ kiểm chứng RLVR.
- **Process Reward Model (PRM):**
  Cấp điểm thưởng r_k sau từng bước trung gian s_k (Lightman et al., 2023). Tín hiệu dày đặc (*Dense Credit*), định vị chính xác bước sai.

Giới hạn của PRM trong thực nghiệm

1. **Step Boundary Ambiguity:**
   Tư duy tự do (thử sai, quay lui) không thể chia thành các bước cứng nhắc.
2. **Chi phí gán nhãn lớn:**
   Không tự kiểm chứng được bước nháp; cần người gán nhãn hoặc duyệt MCTS.
3. **Step-level Reward Hacking:**
   Policy chia nhỏ các bước hiển nhiên ($1 = 1 \implies 2 = 2$) để tích lũy điểm giả.

Thách thức của PPO trên chuỗi suy luận dài

Mạng Critic V_ψ trở thành điểm nghẽn nghiêm trọng khi chuỗi suy luận mở rộng.

- **Gánh nặng VRAM:** Critic V_ψ quy mô 70B–671B chiếm nhiều bộ nhớ GPU.
- **Bất ổn định:** Nhiễu loạn Advantage dễ gây sập chính sách khi CoT dài.

GRPO: Khử Critic bằng chuẩn hóa nhóm

Thay thế mạng Critic bằng thống kê trung bình nhóm (Shao et al., 2024 – DeepSeekMath).

Nguyên lý ước lượng Advantage từ nhóm mẫu G

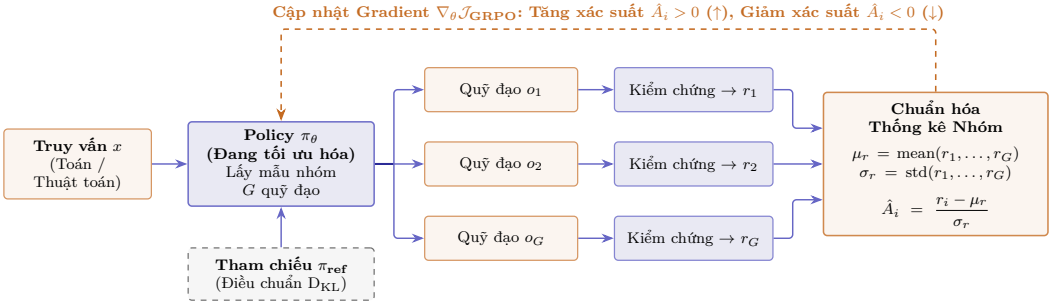
- **Lấy mẫu nhóm:** Rút mẫu song song $\{o_1, \ldots, o_G\} \sim \pi_{\theta_{\text{old}}}(\cdot \mid x)$ và chấm điểm $\{r_1, \ldots, r_G\}$.
- **Chuẩn hóa Z-score nhóm:**

$$\mu_r = \text{mean}(r_1, \ldots, r_G), \quad \sigma_r = \text{std}(r_1, \ldots, r_G) \implies \boxed{\hat{A}_i = \frac{r_i - \mu_r}{\sigma_r}}$$

- **Lợi ích cốt lõi: Khử bỏ hoàn toàn mạng Critic** V_ψ, tiết kiệm 50% VRAM và triệt tiêu sai số xấp xỉ.

RLVR + GRPO: luồng huấn luyện

Lấy mẫu nhóm G quỹ đạo và cập nhật Policy, không cần Value Network.



PPO-Clip kết hợp chuẩn hóa phần thưởng theo nhóm (Shao et al., 2024).

Hàm mục tiêu GRPO

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E}\left[\frac{1}{G}\sum_{i=1}^{G}\frac{1}{|o_i|}\sum_{t=1}^{|o_i|}\left(\min\left(\rho_{i,t}\hat{A}_i,\ \text{clip}(\rho_{i,t}, 1-\epsilon, 1+\epsilon)\hat{A}_i\right) - \beta\, \mathrm{D}_{\text{KL}}\right)\right]$$

Đặc tính cốt lõi

- **Advantage đồng nhất cấp chuỗi ($\hat{A}_{i,t} \equiv \hat{A}_i$):**
  Mọi token trong chuỗi o_i chia sẻ chung trọng số Advantage $\hat{A}_i$.
- **Tự thích nghi theo độ khó bài toán:**
  Chuẩn hóa Z-score duy trì $\mathbb{E}[\hat{A}_i] = 0, \text{Var}(\hat{A}_i) = 1$ ổn định trên mọi tác vụ.

Thiết kế phần thưởng tối giản trong GRPO

DeepSeek-R1-Zero học suy luận trực tiếp từ Base Model mà không qua SFT.

- **Accuracy Reward ($r_{\text{acc}} \in \{0, 1\}$):** Tính đúng đắn của đáp số cuối cùng.
- **Format Reward ($r_{\text{format}} \in \{0, 1\}$):** Tuân thủ thẻ `<think>` và `<answer>`.
- **Không áp đặt nội dung:** Hoàn toàn không ràng buộc độ dài hay ngôn ngữ trong thẻ `<think>`.

Sự nảy sinh tư duy System 2 (Aha Moment)

Cơ chế tự sửa sai và phân bổ thời gian suy nghĩ nảy sinh tự nhiên qua Online RL.

- **Phân bổ token động:** Mô hình tự mở rộng chuỗi `<think>` để phân rã bài toán và thử nghiệm.
- **Khoảnh khắc tự sửa sai (Aha Moment):** Tự phát hiện bước sai trước đó và quay lui (*Backtracking*).
- **Chuyển dịch nhận thức:** Từ **Phản xạ System 1** sang **Suy luận thận trọng System 2**.

Test-time Scaling Laws

Mở rộng năng lực mô hình thông qua tính toán lúc suy diễn (Snell et al., 2024).

- **Sequential Scaling:** Kéo dài chuỗi `<think>` để tự kiểm chứng sâu.
- **Parallel Scaling:** Lấy mẫu N quỹ đạo độc lập; hợp nhất qua **Best-of-N** hoặc **Majority Voting**.
- **Quy luật:** Chi phí tính toán lúc suy diễn có thể bù đắp và vượt trội việc mở rộng kích thước mô hình.