Tối đa hóa phần thưởng kết hợp KL regularization (Ouyang et al., 2022).

Mục tiêu RLHF có điều chuẩn KL (1)

$$\max_{\theta} \; J_{\text{RLHF}}(\theta) = \mathbb{E}_{x\sim\mathcal{D},\, y\sim\pi_\theta}\left[R_{\text{total}}(x,y)\right], \quad \text{với } R_{\text{total}}(x,y) = r_\phi(x,y) - \beta \log \frac{\pi_\theta(y \mid x)}{\pi_{\text{ref}}(y \mid x)}$$

Policy Gradient với hàm Advantage $A(x,y)$ (2)

$$\nabla_\theta J_{\text{RLHF}}(\theta) = \mathbb{E}_{x\sim\mathcal{D},\, y\sim\pi_\theta}\Big[\underbrace{\left(R_{\text{total}}(x,y) - b(x)\right)}_{\text{Advantage } A(x,y)} \nabla_\theta \log \pi_\theta(y \mid x)\Big]$$

Ý nghĩa của Baseline $b(x)$ và Advantage $A(x,y)$

- **Baseline $b(x)$:** Mốc kỳ vọng của prompt x (giúp giảm phương sai gradient mà không gây chệch).
- **Advantage $A(x,y) = R_{\text{total}} - b(x)$:** Đo mức vượt trội so với mốc $b(x)$ ($A > 0$: tăng ↑; $A < 0$: giảm ↓).

Cách 2: Đánh số bên phải trong công thức

Tối đa hóa phần thưởng kết hợp KL regularization (Ouyang et al., 2022).

Mục tiêu RLHF có điều chuẩn KL

$$\max_{\theta} \; J_{\text{RLHF}}(\theta) = \mathbb{E}_{x\sim\mathcal{D},\, y\sim\pi_\theta}\left[R_{\text{total}}(x,y)\right], \quad \text{với } R_{\text{total}}(x,y) = r_\phi(x,y) - \beta \log \frac{\pi_\theta(y \mid x)}{\pi_{\text{ref}}(y \mid x)} \tag{1}$$

Policy Gradient với hàm Advantage $A(x,y)$

$$\nabla_\theta J_{\text{RLHF}}(\theta) = \mathbb{E}_{x\sim\mathcal{D},\, y\sim\pi_\theta}\Big[\underbrace{\left(R_{\text{total}}(x,y) - b(x)\right)}_{\text{Advantage } A(x,y)} \nabla_\theta \log \pi_\theta(y \mid x)\Big] \tag{2}$$

Ý nghĩa của Baseline $b(x)$ và Advantage $A(x,y)$

- **Baseline** $b(x)$**:** Mốc kỳ vọng của prompt x (giúp giảm phương sai gradient mà không gây chệch).
- **Advantage** $A(x,y) = R_{\textbf{total}} - b(x)$**:** Đo mức vượt trội so với mốc $b(x)$ ($A > 0$: tăng ↑; $A < 0$: giảm ↓).

Tối đa hóa phần thưởng kết hợp KL regularization (Ouyang et al., 2022).

(1) Mục tiêu RLHF có điều chuẩn KL

$$\max_{\theta} \; J_{\text{RLHF}}(\theta) = \mathbb{E}_{x\sim\mathcal{D},\, y\sim\pi_\theta}\left[R_{\text{total}}(x,y)\right], \quad \text{với } R_{\text{total}}(x,y) = r_\phi(x,y) - \beta \log \frac{\pi_\theta(y \mid x)}{\pi_{\text{ref}}(y \mid x)}$$

(2) Policy Gradient với hàm Advantage $A(x,y)$

$$\nabla_\theta J_{\text{RLHF}}(\theta) = \mathbb{E}_{x\sim\mathcal{D},\, y\sim\pi_\theta}\Big[\underbrace{\left(R_{\text{total}}(x,y) - b(x)\right)}_{\text{Advantage } A(x,y)} \nabla_\theta \log \pi_\theta(y \mid x)\Big]$$

Ý nghĩa của Baseline $b(x)$ và Advantage $A(x,y)$

- **Baseline** $b(x)$**:** Mốc kỳ vọng của prompt x (giúp giảm phương sai gradient mà không gây chệch).
- **Advantage** $A(x,y) = R_{\textbf{total}} - b(x)$**:** Đo mức vượt trội so với mốc $b(x)$ ($A > 0$: tăng ↑; $A < 0$: giảm ↓).