Phương án A: Dùng underbrace ở cả hai khối

Tối đa hóa phần thưởng kết hợp KL regularization (Ouyang et al., 2022).

Mục tiêu RLHF có điều chuẩn KL

$$\max_{\theta} \; J_{\text{RLHF}}(\theta) = \mathbb{E}_{x\sim\mathcal{D},\, y\sim\pi_\theta}\Big[\underbrace{r_\phi(x,y) - \beta \log \frac{\pi_\theta(y \mid x)}{\pi_{\text{ref}}(y \mid x)}}_{R_{\text{total}}(x,y)\ \text{(Thưởng tổng hợp)}}\Big]$$

Policy Gradient với hàm Advantage $A(x, y)$

$$\nabla_\theta J_{\text{RLHF}}(\theta) = \mathbb{E}_{x\sim\mathcal{D},\, y\sim\pi_\theta}\Big[\underbrace{\big(R_{\text{total}}(x,y) - b(x)\big)}_{\text{Advantage } A(x,y)} \nabla_\theta \log \pi_\theta(y \mid x)\Big]$$

Ý nghĩa của Baseline $b(x)$ và Advantage $A(x, y)$

- **Baseline** $b(x)$**:** Mốc kỳ vọng của prompt x (giúp giảm phương sai gradient mà không gây chệch).
- **Advantage** $A(x, y)$**:** Đo mức vượt trội so với mốc $b(x)$ ($A > 0$: tăng xác suất ↑; $A < 0$: ghìm

Phương án B: Đặt biểu thức rõ ràng

Tối đa hóa phần thưởng kết hợp KL regularization (Ouyang et al., 2022).

Mục tiêu RLHF có điều chuẩn KL

$$\max_{\theta} \; J_{\text{RLHF}}(\theta) = \mathbb{E}_{x\sim\mathcal{D},\, y\sim\pi_\theta}\left[R_{\text{total}}(x,y)\right], \quad \text{với } R_{\text{total}}(x,y) = r_\phi(x,y) - \beta \log \frac{\pi_\theta(y \mid x)}{\pi_{\text{ref}}(y \mid x)}$$

Policy Gradient với hàm Advantage $A(x,y)$

$$\nabla_\theta J_{\text{RLHF}}(\theta) = \mathbb{E}_{x\sim\mathcal{D},\, y\sim\pi_\theta}\Big[\underbrace{\left(R_{\text{total}}(x,y) - b(x)\right)}_{\text{Advantage } A(x,y)} \nabla_\theta \log \pi_\theta(y \mid x)\Big]$$

Ý nghĩa của Baseline $b(x)$ và Advantage $A(x,y)$

- **Baseline** $b(x)$**:** Mốc kỳ vọng của prompt x (giúp giảm phương sai gradient mà không gây chệch).
- **Advantage** $A(x,y)$**:** Đo mức vượt trội so với mốc $b(x)$ ($A > 0$: tăng xác suất ↑; $A < 0$: ghìm xác suất ↓).