CƠ SỞ TOÁN HỌC VÀ SỰ TIẾN HÓA THUẬT TOÁN HẬU HUẤN LUYỆN MÔ HÌNH NGÔN NGỮ LỚN (2020–2026)

Phần 1: SFT (2020–2021) · Phần 2: RLHF & PPO (2022) · Phần 3: DPO (2023–2024) · Phần 4: RLVR & GRPO (2024–2026) · Phần 5: Chưng cất Tri thức

Chuyên đề Seminar Khoa học Máy tính & Trí tuệ Nhân tạo

Giải tích Tối ưu hóa, Kiến trúc Luồng Dữ liệu và Động cơ Tiến hóa Phương pháp

Thời lượng trình bày: 90–120 Phút

Mục lục Tổng quan Báo cáo Seminar

Tiến trình Lịch sử (2020–2026) & Chưng cất Tri thức

1. Phần 1 (2020–2021): Từ Tiền huấn luyện đến Tinh chỉnh có Giám sát (SFT)

2. Phần 2 (2022–Đầu 2023): Căn chỉnh Mô hình bằng Học Tăng cường (RLHF & PPO)

3. Phần 3 (2023–2024): Tối ưu hóa Chính sách Trực tiếp (DPO & Các Biến thể)

4. Phần 4 (Cuối 2024–2026): Học Tăng cường Kiểm chứng & Suy luận (RLVR & GRPO)

5. Phần 5: Chưng cất Tri thức, Không gian Tham số & Tổng kết Hệ thống

Cấu trúc Tổng kết Cuối mỗi Phần

Kết thúc mỗi Phần đều tổng hợp rõ: **(1) Đóng góp toán học & tối ưu hệ thống đạt được so với giai đoạn trước**, và **(2) Giới hạn tồn đọng chuyển giao cho Phần tiếp theo giải quyết**.

Mục lục Tiến trình Seminar (2020–2026)

Cấu trúc Học thuật & Vị trí Phần Hiện tại

1. Phần 1 (2020–2021): Từ Tiền huấn luyện đến Tinh chỉnh có Giám sát (SFT)
1.1 1.1. Bối cảnh Lịch sử (2020–2026) & Sự Lệch Mục tiêu của Tiền huấn luyện
1.2 1.2. Tinh chỉnh theo Chỉ thị có Giám sát (SFT – Giai đoạn 2021–2022)
1.3 1.3. Tổng kết Phần 1 (SFT): Thành tựu & Các Vấn đề Tồn đọng cho Phần 2

2. Phần 2 (2022–Đầu 2023): Căn chỉnh Mô hình bằng Học Tăng cường (RLHF & PPO)

3. Phần 3 (2023–2024): Tối ưu hóa Chính sách Trực tiếp (DPO & Các Biến thể)

4. Phần 4 (Cuối 2024–2026): Học Tăng cường Kiểm chứng & Suy luận (RLVR & GRPO)

5. Phần 5: Chưng cất Tri thức, Không gian Tham số & Tổng kết Hệ thống

Công thức 1: Hàm Mục tiêu Dự đoán Token Tiếp theo (Autoregressive MLE)

$$\mathcal{L}_{\text{Pretrain}}(\theta) = -\sum_{t=1}^{T} \log P_\theta(u_t \mid u_1, u_2, \ldots, u_{t-1})$$

Đặc tính Toán học của Mô hình Nền (Base Model)

- **Xấp xỉ phân phối biên ngôn ngữ:** Học phân phối có điều kiện $P_\theta(u_t \mid u_{<t})$ trên kho văn bản quy mô 10^{12}–10^{13} token.
- **Nội hóa tri thức thế giới:** Nén cấu trúc cú pháp, tri thức sự kiện (factual knowledge) và quy luật suy diễn vào không gian tham số θ.
- **Giới hạn năm 2020:** Vận hành thuần túy như bộ nối tiếp chuỗi xác suất; phụ thuộc hoàn toàn vào kỹ thuật đặt ví dụ trong ngữ cảnh (*Few-shot In-Context Learning*).

Hạn chế của Tiền huấn luyện (Pre-training)

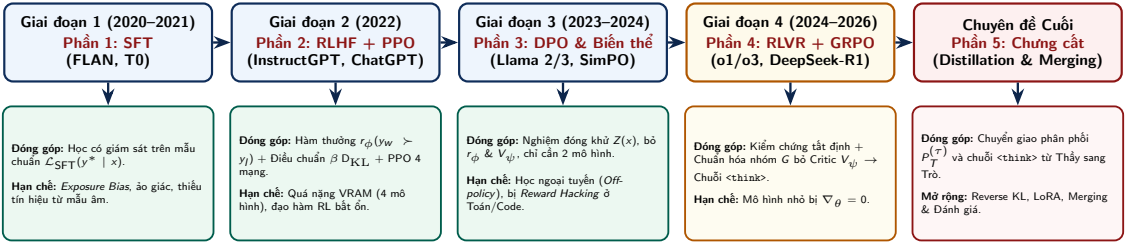
- **Lệch mục tiêu tối ưu hóa:**
  - Đầu vào x: *"Giải thích nguyên lý của laser?"*
  - Đầu ra Base Model: Sinh tiếp các câu hỏi số 2, số 3 thay vì trả lời.
- **Không phân biệt chất lượng dữ liệu:**
  - Tái tạo cả sai số thực tế, định kiến và nội dung độc hại từ tập dữ liệu web.

Mục tiêu của Hậu huấn luyện (Post-Training)

- **Định hướng phân phối phản hồi:** Chuyển dịch từ $P_\theta(u_t \mid u_{<t})$ sang phân phối phản hồi theo chỉ thị $\pi_\theta(y \mid x)$.
- **Ba tiêu chuẩn căn chỉnh (3H Criteria):**
  1. **Helpful (Hữu ích):** Giải quyết đúng yêu cầu.
  2. **Honest (Trung thực):** Hạn chế bịa đặt thông tin.
  3. **Harmless (An toàn):** Từ chối tác vụ độc hại.

Phần 1.1: Biên niên sử Tiến hóa Hậu Huấn luyện (2020 – 2026)

Dòng Chảy Lịch sử qua Năm Giai đoạn Chuyển dịch Thuật toán



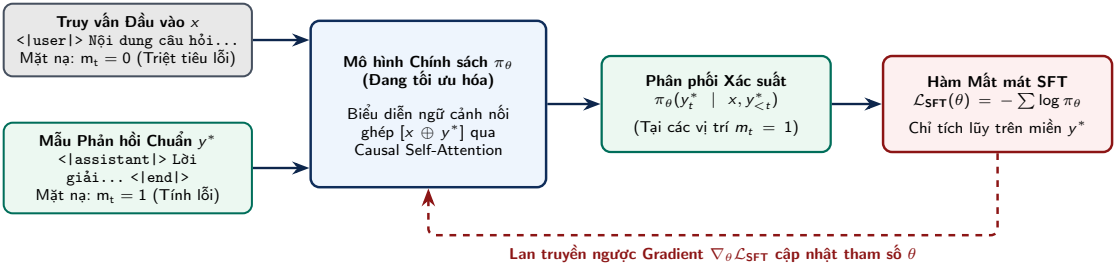
Quy luật tiến hóa: Giới hạn toán học và hệ thống của giai đoạn trước là động cơ trực tiếp sinh ra thuật toán của giai đoạn kế tiếp.

Định dạng Dữ liệu Giám sát và Token Điều khiển

- **Tập dữ liệu:** $\mathcal{D}_{\text{SFT}} = \{(x^{(i)}, y^{*(i)})\}_{i=1}^{N}$ gồm truy vấn đầu vào x và mẫu phản hồi chuẩn y^*.
- **Phân vùng ngữ cảnh bằng Token đặc biệt (Control Tokens):**
  - `<|im_start|>system ... <|im_end|>` $\longrightarrow$ Ràng buộc hệ thống toàn cục.
  - `<|im_start|>user ... <|im_end|>` $\longrightarrow$ Miền truy vấn đầu vào x.
  - `<|im_start|>assistant ... <|im_end|>` $\longrightarrow$ Miền sinh phản hồi mục tiêu y^*.

Ý nghĩa Toán học của Token Kết thúc <EOS> (<|im_end|>)

Đưa <EOS> vào miền tính đạo hàm giúp mô hình ước lượng chính xác xác suất dừng chuỗi $P_\theta(\texttt{<EOS>} \mid x, y^*_{\leq T})$, triệt tiêu hiện tượng sinh văn bản tràn lan của Base Model.



Nguyên lý tính toán: Truy vấn x tham gia tính ma trận Key–Value Attention ở lượt truyền thuận, nhưng bị khóa đạo hàm ở lượt truyền ngược nhờ mặt nạ $m_t = 0$.

Công thức 2: Hàm Mất mát Tinh chỉnh có Giám sát (Conditional MLE Loss)

$$\mathcal{L}_{\text{SFT}}(\theta) = -\,\mathbb{E}_{(x,y^*)\sim\mathcal{D}_{\text{SFT}}}\left[\sum_{t=1}^{|y^*|} \log \pi_\theta\left(y_t^* \;\middle|\; x, y_1^*, \ldots, y_{t-1}^*\right)\right]$$

Bản chất Giải tích

- **Quy tắc dây chuyền xác suất:**
  $\log \pi_\theta(y^* \mid x) = \sum_{t=1}^{|y^*|} \log \pi_\theta(y_t^* \mid x, y_{<t}^*)$.
- **Tương đương Phân kỳ KL Thuận:**
  $\arg\min_\theta \mathcal{L}_{\text{SFT}}(\theta) \equiv \arg\min_\theta \mathrm{D}_{\mathrm{KL}}(P_{\text{data}} \,\|\, \pi_\theta)$.

Lý do loại trừ $\log \pi_\theta(x)$

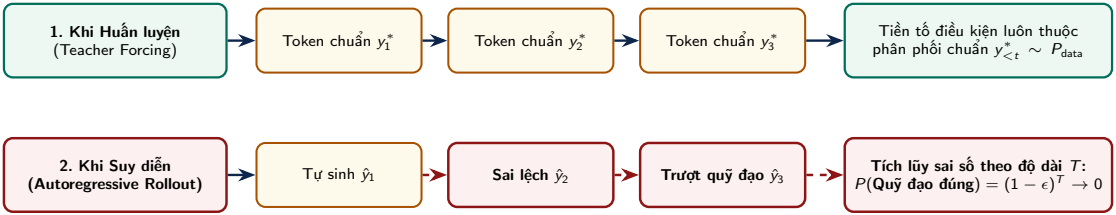
- Chỉ tối ưu hóa phân phối có điều kiện $P(Y \mid X)$, không mô hình hóa phân phối biên $P(X)$.
- Tập trung toàn bộ dung lượng tham số vào miền sinh phản hồi y^*.

1. Giả thuyết LIMA (2023)

- **Căn chỉnh bề mặt (Superficial Alignment):** Tri thức cốt lõi đã nằm trong Base Model; SFT chỉ ánh xạ biểu diễn nội tại ra định dạng giao tiếp chuẩn.
- **Ưu tiên chất lượng hơn số lượng:** 1,000 mẫu chuẩn xác cao vượt trội so với 50,000 mẫu thu thập đại trà chứa nhiễu.

2. Lọc Mẫu & Suy thoái Phân phối

- **Lọc mẫu theo ngưỡng (Rejection Sampling):** Sinh N ứng viên $\{y_1, \ldots, y_N\} \sim \pi_\theta$, dùng hàm đánh giá lọc lấy mẫu đạt điểm cao nhất đưa vào $\mathcal{D}_{\text{SFT}}$.
- **Suy thoái phân phối (Model Collapse):** Huấn luyện đệ quy trên dữ liệu tổng hợp không kiểm chứng làm co hẹp miền giá trị (*Support Shrinkage*) và mất phương sai vùng đuôi.



Sự Dịch chuyển Phân phối Trạng thái (Covariate Shift – Ross et al., 2011)

Khi huấn luyện: $s_t = (x, y_{<t}^*) \sim P_{\text{data}}$. Khi suy diễn: $\hat{s}_t = (x, \hat{y}_{<t}) \sim \pi_\theta$. Với sai số bước $\epsilon = 0.01$ và độ dài $T = 200$, xác suất giữ đúng quỹ đạo giảm còn $(0.99)^{200} \approx 13.4\%$.

Những gì SFT Đã Giải quyết & Tối ưu hơn so với Pre-training

Tiêu chí Đánh giá	Tiền huấn luyện – Base Model (2020)	Tinh chỉnh SFT (Phần 1 – 2021–2022)
1. Hàm mục tiêu	$\mathcal{L}_{\text{MLE}}(u_t \mid u_{<t})$ trên toàn chuỗi	$\mathcal{L}_{\text{SFT}}(y_t^* \mid x, y_{<t}^*)$ với mặt nạ $m_t = 0$ trên x
2. Chế độ vận hành	Chỉ nối tiếp văn bản, phụ thuộc mồi mẫu Few-shot	**Khắc phục Objective Mismatch**: Giải quyết chỉ thị trực tiếp ở chế độ Zero-shot
3. Kiểm soát độ dài	Sinh tràn lan tới giới hạn cửa sổ ngữ cảnh	Ước lượng chính xác xác suất dừng chuỗi tại <EOS>
4. Độ phức tạp hệ thống	Hàng nghìn tỷ token, chi phí tính toán khổng lồ	Chỉ cần 10^3–10^5 mẫu trên **1 mô hình** (π_θ), tối ưu hóa lồi cục bộ ổn định

Ba Bài toán Mở mà SFT Không thể Tự Giải quyết

1. **Lệch Phân phối Tiếp xúc (Exposure Bias):**
   Mô hình chỉ quan sát tiền tố mẫu $y^*_{<t} \sim P_{\text{data}}$, chưa bao giờ được huấn luyện trên chuỗi tự sinh $\hat{y} \sim \pi_\theta$.

2. **Kích thích Ảo giác Ngoại lai (Extrinsic Hallucination):**
   Cực đại hóa $\log \pi_\theta(y^* \mid x)$ trên cả tri thức nằm ngoài Base Model khiến mô hình suy giảm hiệu chỉnh xác suất (Miscalibration) và sinh thông tin bịa đặt.

3. **Thiếu vắng Tín hiệu từ Mẫu Âm (Absence of Negative Samples):**
   SFT chỉ gia tăng xác suất cho mẫu dương chuẩn y^* ($\uparrow$), không có đạo hàm phạt ($\downarrow$) đối với các mẫu âm sai lệch y_l.

Bài toán Chuyển giao sang Phần 2 (RLHF & PPO – 2022)

Thiết kế cơ chế học từ **cặp đối chiếu gồm Mẫu dương y_w và Mẫu âm y_l**, kết hợp lấy mẫu trực tuyến $\hat{y} \sim \pi_\theta$ để khử *Exposure Bias*.

Mục lục Tiến trình Seminar (2020–2026)

Cấu trúc Học thuật & Vị trí Phần Hiện tại

1. Phần 1 (2020–2021): Từ Tiền huấn luyện đến Tinh chỉnh có Giám sát (SFT)

2. Phần 2 (2022–Đầu 2023): Căn chỉnh Mô hình bằng Học Tăng cường (RLHF & PPO)
2.1 2.1. Dữ liệu Đối chiếu Cặp (y_w, y_l) & Mô hình Định giá Thưởng (r_ϕ)
2.2 2.2. Định luật Goodhart, Điều chuẩn Phân kỳ KL ($\beta\, \mathrm{D}_{\mathrm{KL}}$) & Chu trình RL
2.3 2.3. Đạo hàm Chính sách, Thuật toán PPO (Mạng Giá trị V_ψ) & Hệ thống 4 Mô hình
2.4 2.4. Tổng kết Phần 2 (RLHF + PPO): Thành tựu & Các Vấn đề Tồn đọng cho Phần 3

3. Phần 3 (2023–2024): Tối ưu hóa Chính sách Trực tiếp (DPO & Các Biến thể)

4. Phần 4 (Cuối 2024–2026): Học Tăng cường Kiểm chứng & Suy luận (RLVR & GRPO)

5. Phần 5: Chưng cất Tri thức, Không gian Tham số & Tổng kết Hệ thống

Bất đối xứng Độ phức tạp giữa Bài toán Sinh (Generation) và Kiểm định (Verification)

Thay vì biên soạn nhãn chuẩn y^* như SFT, mô hình sinh cặp ứng viên $(y_1, y_2) \sim \pi_{\text{SFT}}(\cdot \mid x)$ để xác lập quan hệ thứ tự $y_w \succ y_l$ (**Mẫu dương** y_w ưu việt hơn **Mẫu âm** y_l):

Hạn chế của Định lượng Vô hướng Tuyệt đối

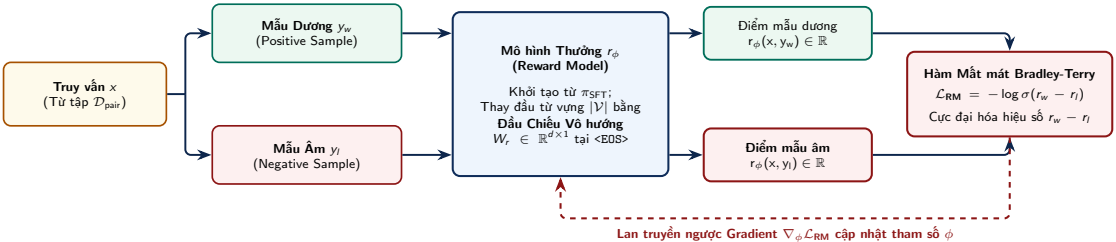
- **Phương sai cá nhân cao:** Thang điểm tuyệt đối (1–10) không đồng nhất giữa những người đánh giá.
- **Trôi chuẩn định lượng (Calibration Drift):** Ngưỡng chấm của cùng một chuyên gia biến thiên theo thời gian.

Ưu thế của Cặp Đối chiếu ($y_w \succ y_l$)

- **Bất biến với thang đo:** Quan hệ nhị phân $y_w \succ y_l$ có độ đồng thuận thống kê cao.
- **Bổ sung Mẫu âm y_l (Negative Sample):** Cung cấp biên phân cách rõ ràng để triệt tiêu hành vi sai lệch.

Phần 2.1: Sơ đồ Kiến trúc & Luồng Dữ liệu Huấn luyện Mô hình Thưởng (r_ϕ)

Học Hàm Định giá Vô hướng $r_\phi(x, y) \in \mathbb{R}$ từ Cặp Mẫu Dương y_w và Mẫu Âm y_l



Nguyên lý vận hành: Cặp (x, y_w) và (x, y_l) đi qua cùng mạng r_ϕ; đạo hàm đẩy điểm của mẫu dương $r_\phi(x, y_w)$ tăng lên ($\uparrow$) và điểm của mẫu âm $r_\phi(x, y_l)$ giảm xuống ($\downarrow$).

Công thức 3: Mô hình Xác suất Bradley-Terry (1952) & Hàm Mất mát $\mathcal{L}_{\text{RM}}(\phi)$

$$P(y_w \succ y_l \mid x) = \sigma\big(r_\phi(x, y_w) - r_\phi(x, y_l)\big), \qquad \mathcal{L}_{\text{RM}}(\phi) = -\,\mathbb{E}_{(x,y_w,y_l)\sim\mathcal{D}_{\text{pair}}}\Big[\log \sigma\big(r_\phi(x, y_w) - r_\phi(x, y_l)\big)\Big]$$

Tính chất Bất biến Tịnh tiến theo Trạng thái Truy vấn (Shift Invariance)

- **Biểu diễn vô hướng tại <EOS>:** $r_\phi(x, y) = W_r^\top h_{\text{EOS}}(x, y) \in \mathbb{R}$ (do mặt nạ Causal Attention hội tụ toàn bộ tiền tố tại token cuối).
- **Bất biến tịnh tiến:** Với mọi hàm $C(x)$ chỉ phụ thuộc truy vấn x, phép biến đổi $\tilde{r}(x, y) = r(x, y) + C(x)$ bảo toàn hiệu số:

$$\tilde{r}(x, y_w) - \tilde{r}(x, y_l) = r(x, y_w) - r(x, y_l) \implies P_{\tilde{r}}(y_w \succ y_l \mid x) \equiv P_r(y_w \succ y_l \mid x)$$

Định luật Goodhart & Trục lợi Phần thưởng

- **Định luật Goodhart:** Khi hàm xấp xỉ r_ϕ bị tối ưu hóa cực đoan, nó mất tính tương quan với chất lượng thực tế.
- **Sai số ngoại suy (OOD Error):** r_ϕ chỉ chính xác trong lân cận phân phối của π_{SFT}.
- **Trục lợi phần thưởng (Reward Hacking – Gao et al., 2023):** Chính sách π_θ dịch chuyển sang vùng ngoại lai để khai thác cực đại giả của r_ϕ.

Giải pháp: Điều chuẩn Vùng Tin cậy bằng D_{KL}

- Cố định mô hình SFT làm **Mô hình Tham chiếu (π_{ref})** và phạt độ lệch phân phối:

$$D_{\text{KL}}\left(\pi_\theta(\cdot \mid x) \,\|\, \pi_{\text{ref}}(\cdot \mid x)\right) = \mathbb{E}_{y \sim \pi_\theta}\left[\log \frac{\pi_\theta(y \mid x)}{\pi_{\text{ref}}(y \mid x)}\right]$$

- **Tác dụng:** Neo π_θ trong vùng tin cậy của r_ϕ và bảo toàn cấu trúc ngôn ngữ gốc.

Công thức 4: Hàm Mục tiêu Tối ưu hóa Chính sách RLHF (KL-Regularized RL Objective)

$$\max_{\pi_\theta} J_{\text{RLHF}}(\pi_\theta) = \mathbb{E}_{x\sim\mathcal{D},\, y\sim\pi_\theta(y|x)} \Big[\underbrace{r_\phi(x,y)}_{\text{Điểm định giá } r_\phi} - \beta \underbrace{\log \frac{\pi_\theta(y \mid x)}{\pi_{\text{ref}}(y \mid x)}}_{\text{Điều chuẩn phân kỳ KL}} \Big]$$

Tín hiệu Phần thưởng Hiệu dụng (Effective Reward) & Hệ số Điều chuẩn $\beta > 0$

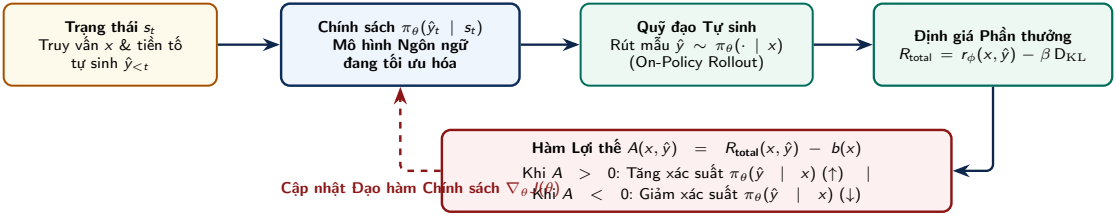
- Phần thưởng tổng hợp tại mỗi bước lấy mẫu trực tuyến $y \sim \pi_\theta(\cdot \mid x)$:

$$R_{\text{total}}(x,y) = r_\phi(x,y) - \beta \log \frac{\pi_\theta(y \mid x)}{\pi_{\text{ref}}(y \mid x)}$$

- **Giới hạn tiệm cận:** Khi $\beta \to 0 \implies$ suy biến do *Reward Hacking*; khi $\beta \to +\infty \implies$ chính sách bất động ($\pi_\theta \equiv \pi_{\text{ref}}$).

Phần 2.2: Chu trình Học Tăng cường Trực tuyến (On-Policy RL Loop)

Cơ chế Tự Sinh Mẫu $\hat{y} \sim \pi_\theta$ Khắc phục Triệt để Hiện tượng Exposure Bias của Phần 1



Khắc phục Exposure Bias: Chính sách π_θ được huấn luyện trực tiếp trên các trạng thái tự sinh $\hat{s}_t = (x, \hat{y}_{<t}) \sim \pi_\theta$ và nhận phạt âm ($A < 0$) ngay khi đi chệch quỹ đạo.

Công thức 5: Đạo hàm Chính sách (REINFORCE với Baseline) & Hàm Lợi thế $A(x, y)$

$$\nabla_\theta J(\theta) = \mathbb{E}_{x\sim\mathcal{D},\, y\sim\pi_\theta(\cdot|x)} \Big[\underbrace{\big(R_{\text{total}}(x,y) - b(x)\big)}_{\text{Hàm Lợi thế } A(x,y)} \nabla_\theta \log \pi_\theta(y \mid x) \Big]$$

1. Đồng nhất thức Đạo hàm Logarit

- Phép rút mẫu rời rạc $y \sim \pi_\theta$ không có đạo hàm $\frac{\partial y}{\partial \theta}$.
- Áp dụng $\nabla_\theta \pi_\theta = \pi_\theta \nabla_\theta \log \pi_\theta$:

$$\nabla_\theta \sum_y \pi_\theta(y) R(y) = \mathbb{E}_{y\sim\pi_\theta} \left[R(y) \nabla_\theta \log \pi_\theta(y) \right]$$

2. Vai trò của Đường cơ sở $b(x) = \mathbb{E}[R]$

- Phân tách dấu giữa quỹ đạo trên trung bình ($A > 0, \uparrow$) và dưới trung bình ($A < 0, \downarrow$).
- Giảm phương sai ước lượng Monte Carlo mà không làm chệch kỳ vọng (do $\mathbb{E}[b(x)\nabla_\theta \log \pi_\theta] = 0$).

Công thức 6: Hàm Mục tiêu Cắt tỉa Cận biên (PPO-Clip Objective)

$$\mathcal{J}_{\text{PPO-Clip}}(\theta) = \mathbb{E}_t\left[\min\left(\rho_t(\theta)\hat{A}_t,\ \text{clip}\left(\rho_t(\theta), 1-\epsilon, 1+\epsilon\right)\hat{A}_t\right)\right], \qquad \rho_t(\theta) = \frac{\pi_\theta(y_t \mid x, y_{<t})}{\pi_{\theta_{\text{old}}}(y_t \mid x, y_{<t})}$$

Cơ chế Chặn Biên $\text{clip}(\rho_t, 1-\epsilon, 1+\epsilon)$

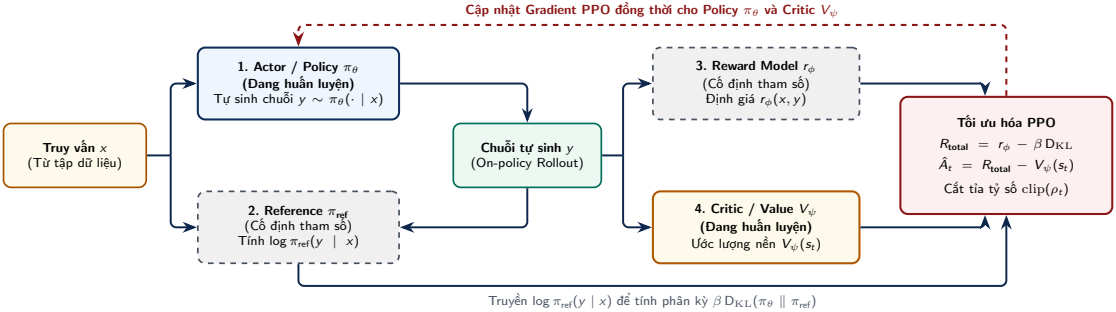
- $\rho_t(\theta)$: Tỷ số xác suất của token y_t giữa chính sách mới và chính sách lúc lấy mẫu.
- Khi $|\rho_t(\theta) - 1| > \epsilon$ (với $\epsilon = 0.2$), toán tử $\min(\cdot)$ triệt tiêu đạo hàm về 0, ngăn bước cập nhật quá lớn.

Mạng Giá trị (Critic) $V_\psi(s_t)$

- Ước lượng đường cơ sở kỳ vọng tại từng vị trí token t: $\hat{A}_t = R_t - V_\psi(s_t)$.
- Đòi hỏi duy trì một mạng nơ-ron V_ψ có quy mô tham số tương đương mô hình chính π_θ.

Phần 2.3: Sơ đồ Kiến trúc & Luồng Dữ liệu của Hệ thống RLHF + PPO (4 Mô hình)

Cấu trúc Phối hợp Bốn Mạng Nơ-ron Đồng thời trên Bộ nhớ GPU



Những gì RLHF + PPO Đã Giải quyết & Tối ưu hơn so với SFT

Tiêu chí Đánh giá	Tinh chỉnh SFT (Phần 1 – 2021)	RLHF + PPO (Phần 2 – 2022)
1. Phân phối trạng thái	Học tĩnh trên tiền tố chuyên gia $y^*_{<t}$ (*Teacher Forcing*)	**Khử Exposure Bias**: Học trực tuyến trên chuỗi tự sinh $\hat{y} \sim \pi_\theta$ (*On-policy*)
2. Tín hiệu đạo hàm	Chỉ có tín hiệu dương ($\uparrow$) trên mẫu chuẩn y^*	**Đạo hàm hai chiều**: Củng cố mẫu dương ($\hat{A}_t > 0, \uparrow$) và chế tài mẫu âm ($\hat{A}_t < 0, \downarrow$)
3. Kiểm soát phân phối	Suy giảm hiệu chỉnh xác suất khi ép học thuộc	Điều chuẩn vùng tin cậy $\beta\, \mathrm{D}_{\mathrm{KL}}(\pi_\theta \parallel \pi_{\mathrm{ref}})$ chống suy biến
4. Hiệu năng thực nghiệm	Phụ thuộc mạnh vào kích thước mô hình nền	**InstructGPT 1.3B** vượt qua **GPT-3 175B** trên đánh giá mù

Ba Rào cản Cốt lõi của Kiến trúc RLHF + PPO

1. **Chi phí Bộ nhớ GPU Gấp 4 Lần (4-Model Memory Bottleneck):**
   Bắt buộc nạp đồng thời **4 mạng nơ-ron lớn** $(\pi_\theta, \pi_{\text{ref}}, r_\phi, V_\psi)$ vào VRAM.

2. **Nút thắt Thời gian Giải mã Tự hồi quy (Autoregressive Rollout Bottleneck):**
   Sinh mẫu tuần tự $\hat{y} \sim \pi_\theta$ tại mỗi bước cập nhật tiêu tốn $> 70\%$ thời gian tính toán.

3. **Phương sai Đạo hàm Cao & Sai số Xấp xỉ Kép (r_ϕ, V_ψ):**
   Sai số ước lượng từ cả mạng thưởng r_ϕ lẫn mạng giá trị V_ψ gây mất ổn định hội tụ.

Bài toán Chuyển giao sang Phần 3 (DPO – 2023)

Giải bài toán tối ưu hóa RLHF bằng **nghiệm đóng giải tích** để cập nhật trực tiếp π_θ từ cặp mẫu dương/âm (y_w, y_l) mà **bỏ hoàn toàn vòng lặp RL, bỏ cả r_ϕ lẫn V_ψ**.

Mục lục Tiến trình Seminar (2020–2026)

Cấu trúc Học thuật & Vị trí Phần Hiện tại

1. Phần 1 (2020–2021): Từ Tiền huấn luyện đến Tinh chỉnh có Giám sát (SFT)

2. Phần 2 (2022–Đầu 2023): Căn chỉnh Mô hình bằng Học Tăng cường (RLHF & PPO)

3. Phần 3 (2023–2024): Tối ưu hóa Chính sách Trực tiếp (DPO & Các Biến thể)
3.1 3.1. Từ Hàm Mục tiêu RLHF đến Hàm Mất mát DPO (Nghiệm Đóng Giải tích)
3.2 3.2. Cơ chế Gradient, Kiến trúc 2 Mô hình & Các Biến thể (2024)
3.3 3.3. Tổng kết Phần 3 (DPO): Thành tựu & Các Vấn đề Tồn đọng cho Phần 4

4. Phần 4 (Cuối 2024–2026): Học Tăng cường Kiểm chứng & Suy luận (RLVR & GRPO)

5. Phần 5: Chưng cất Tri thức, Không gian Tham số & Tổng kết Hệ thống

Ý tưởng Đột phá: Ánh xạ Giải tích Trực tiếp giữa Hàm Thưởng $r(x, y)$ và Chính sách $\pi^*(y \mid x)$

- **Quy trình gián tiếp của RLHF + PPO (Phần 2):**

$$\text{Cặp } (y_w, y_l) \xrightarrow{\text{Bước 1 (MLE)}} \text{Hàm thưởng } r_\phi(x, y) \xrightarrow{\text{Bước 2 (PPO + } V_\psi\text{)}} \text{Chính sách } \pi_\theta(y \mid x)$$

- **Quy trình trực tiếp của DPO (Phần 3):** Giải nghiệm đóng của bài toán cực trị RLHF để biểu diễn ngược $r(x, y)$ theo $\pi_\theta(y \mid x)$, qua đó tối ưu hóa thẳng π_θ trên cặp mẫu dương/âm (y_w, y_l)!

Tiêu chí Hệ thống	RLHF + PPO (Phần 2 – 2022)	DPO (Phần 3 – 2023)
Số mô hình trong VRAM	**4 mạng:** $\pi_\theta, \pi_{\text{ref}}, r_\phi, V_\psi$	**2 mạng:** Chỉ cần π_θ và π_{ref}
Giải mã tự hồi quy lúc học	Bắt buộc ở mọi bước cập nhật (*Rollout*)	**Không cần** (Tính log-prob song song)

1. Mục tiêu RLHF & Nghiệm Đóng (B1)

Bài toán cực trị có điều chuẩn KL:

$$\max_{\pi} \mathbb{E}_{y\sim\pi}\left[r(x,y) - \beta \log \frac{\pi(y \mid x)}{\pi_{\text{ref}}(y \mid x)}\right]$$

Nghiệm cực trị Gibbs–Boltzmann (BĐT Gibbs):

$$\pi^*(y \mid x) = \frac{1}{Z(x)}\pi_{\text{ref}}(y \mid x)\exp\left(\frac{1}{\beta}r(x,y)\right)$$

Biểu diễn ngược hàm thưởng:

$$\boxed{r(x,y) = \beta \log \frac{\pi^*(y \mid x)}{\pi_{\text{ref}}(y \mid x)} + \beta \log Z(x)}$$

($Z(x) = \sum_y \pi_{ref}\exp(\frac{1}{\beta}r)$: hàm phân hoạch)

2. Khử $Z(x)$ & Hàm Mất mát DPO (B7)

Thế vào xác suất cặp Bradley–Terry:
Khi lấy hiệu số $r(x,y_w) - r(x,y_l)$, đại lượng $\beta \log Z(x)$ **tự triệt tiêu hoàn toàn**:

$$r(x,y_w) - r(x,y_l) = \beta \log \frac{\pi^*(y_w \mid x)}{\pi_{\text{ref}}(y_w \mid x)} - \beta \log \frac{\pi^*(y_l \mid x)}{\pi_{\text{ref}}(y_l \mid x)}$$

Công thức 7: Hàm Mất mát DPO (B7)

Thay π^* bằng π_θ, tối ưu MLE trên tập cặp:

$$\mathcal{L}_{\text{DPO}}(\theta) = -\,\mathbb{E}_{(x,y_w,y_l)}\left[\log \sigma\left(\hat{r}_\theta(x,y_w) - \hat{r}_\theta(x,y_l)\right)\right]$$

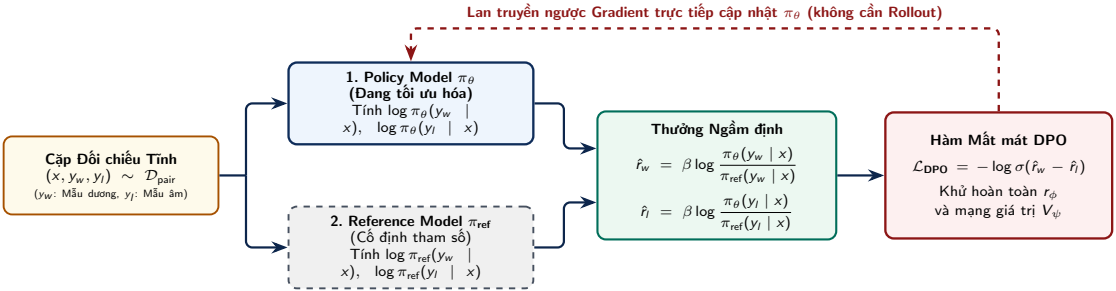
với phần thưởng ngầm định: $\hat{r}_\theta(x,y) = \beta \log \frac{\pi_\theta(y|x)}{\pi_{\text{ref}}(y|x)}$.

Biểu thức Gradient Đầy đủ của Hàm Mất mát DPO (Rafailov et al., 2023)

$$\nabla_\theta \mathcal{L}_{\text{DPO}}(\theta) = -\beta\, \mathbb{E}_{(x,y_w,y_l)} \Big[\underbrace{\sigma\big(\hat{r}_\theta(x,y_l) - \hat{r}_\theta(x,y_w)\big)}_{\text{Hệ số lỗi xếp hạng} \in (0,1)} \cdot \Big(\underbrace{\nabla_\theta \log \pi_\theta(y_w \mid x)}_{\text{Kéo Mẫu dương } y_w\ (\uparrow)} - \underbrace{\nabla_\theta \log \pi_\theta(y_l \mid x)}_{\text{Đẩy Mẫu âm } y_l\ (\downarrow)} \Big) \Big]$$

Ý nghĩa Cơ chế Tự Điều trọng số Động (Dynamic Weighting)

- **Khi mô hình xếp hạng sai ($\hat{r}_\theta(x,y_l) > \hat{r}_\theta(x,y_w)$):**
  Hệ số lỗi $\sigma(\hat{r}_l - \hat{r}_w) > 0.5$ (tiệm cận 1.0), tự động **khuếch đại biên độ gradient** để ép mạng sửa sai triệt để.
- **Khi mô hình đã phân loại đúng ($\hat{r}_\theta(x,y_w) \gg \hat{r}_\theta(x,y_l)$):**
  Hệ số $\sigma(\hat{r}_l - \hat{r}_w) \to 0$, gradient tự triệt tiêu $\to$ **ngăn ngừa quá khớp** trên các mẫu đã học tốt.
- **Tác động đối ngẫu:**
  Đồng thời kéo tăng hợp lý của mẫu dương y_w và triệt hạ xác suất phát sinh mẫu âm y_l.



Ưu thế hệ thống: Tính toán log-xác suất song song trên toàn chuỗi (y_w, y_l) trong một lượt truyền thuận duy nhất.

Ba Hạn chế Giải tích của DPO Chuẩn

1. **Thiên kiến độ dài (Length Bias):**
   Tổng $\log \pi_\theta(y \mid x) = \sum_{t=1}^{|y|} \log \pi_\theta(y_t \mid x, y_{<t})$ tỷ lệ thuận với $|y|$, gây ưu tiên mẫu dài dòng.

2. **Dịch chuyển hợp lý (Likelihood Displacement):**
   Chỉ tối ưu hiệu số $\hat{r}_w - \hat{r}_l$, có thể làm cả $\log \pi_\theta(y_w)$ lẫn $\log \pi_\theta(y_l)$ cùng giảm.

3. **Đòi hỏi cặp đồng truy vấn** (x, y_w, y_l)**:**
   Không tận dụng được dữ liệu đánh giá nhị phân đơn lẻ.

Các Phương pháp Cải tiến (2024)

- **SimPO (Meng et al., 2024):**
  Chuẩn hóa độ dài $\frac{\beta}{|y|} \log \pi_\theta(y \mid x)$ và thay π_{ref} bằng hằng số biên $\gamma > 0$ (chỉ cần **1 mô hình**).

- **RPO / CPO (2024):**
  Cộng thêm $\alpha \mathcal{L}_{\text{SFT}}(y_w)$ để neo xác suất tuyệt đối của mẫu dương y_w.

- **IPO (Azar et al., 2024):**
  Hàm mất mát bình phương ngăn quá khớp khi xác suất cặp tiệm cận 1.

- **KTO (Ethayarajh et al., 2024):**
  Học trực tiếp từ mẫu dương hoặc mẫu âm đơn lẻ.

Những gì DPO Đã Giải quyết & Tối ưu hơn so với RLHF + PPO (Phần 2)

Tiêu chí Đánh giá	RLHF + PPO (Phần 2 – 2022)	DPO & Biến thể (Phần 3 – 2023–2024)
1. Cơ sở giải tích	Xấp xỉ lặp qua đạo hàm Monte Carlo và mạng r_ϕ, V_ψ	**Nghiệm đóng Boltzmann**: Khử hoàn toàn hằng số phân hoạch $\beta \log Z(x)$
2. Bộ nhớ GPU	**4 mạng:** $\pi_\theta, \pi_{\text{ref}}, r_\phi, V_\psi$	**2 mạng** $(\pi_\theta, \pi_{\text{ref}})$ với DPO, hoặc **1 mạng** với SimPO
3. Tốc độ tính toán	Chậm do giải mã tự hồi quy tuần tự (*Rollout*)	**Tăng tốc vượt bậc**: Truyền thuận song song trên cặp (y_w, y_l)
4. Tính ổn định	Phương sai đạo hàm cao, nhạy cảm siêu tham số	Hội tụ ổn định tương đương SFT (ứng dụng trên Llama 3, Qwen 2, Zephyr)

Tại sao Cuối Năm 2024 Giới Nghiên cứu Phải Quay lại Online RL cho Bài toán Suy luận?

1. **Giới hạn Học Ngoại tuyến (Off-Policy Exploration Bottleneck):**
   DPO chỉ tối ưu trên tập cặp tĩnh $\mathcal{D}_{\text{pair}}$ thu thập trước; không thể tự khám phá các quỹ đạo suy luận mới nằm ngoài tập dữ liệu.

2. **Thất bại của Định giá Thần kinh trên Toán học & Thuật toán:**
   Trong bài toán suy luận đa bước, cả DPO lẫn mạng r_ϕ đều bị đánh lừa bởi các lời giải trình bày đẹp nhưng sai kết quả (*Reward Hacking*).

3. **Điểm nghẽn Mạng Giá trị V_ψ khi Quay lại Online RL:**
   Nếu dùng lại PPO (Phần 2) cho chuỗi suy luận dài 10,000 token, mạng Critic V_ψ bị suy biến do phần thưởng thưa ở cuối chuỗi.

Bài toán Chuyển giao sang Phần 4 (RLVR + GRPO – Cuối 2024–2026)

Kết hợp **Bộ kiểm chứng tất định (RLVR)** chống *Reward Hacking* và giải thuật **GRPO** chuẩn hóa nhóm G quỹ đạo để **xóa bỏ mạng Critic V_ψ**.

Mục lục Tiến trình Seminar (2020–2026)

Cấu trúc Học thuật & Vị trí Phần Hiện tại

1. Phần 1 (2020–2021): Từ Tiền huấn luyện đến Tinh chỉnh có Giám sát (SFT)

2. Phần 2 (2022–Đầu 2023): Căn chỉnh Mô hình bằng Học Tăng cường (RLHF & PPO)

3. Phần 3 (2023–2024): Tối ưu hóa Chính sách Trực tiếp (DPO & Các Biến thể)

4. Phần 4 (Cuối 2024–2026): Học Tăng cường Kiểm chứng & Suy luận (RLVR & GRPO)
4.1 4.1. Phần thưởng Kiểm chứng Tất định (RLVR) & Bài toán Gán Tín dụng (ORM vs. PRM)
4.2 4.2. Thuật toán Tối ưu hóa Tương đối Nhóm (GRPO) & Các Tinh chỉnh Mới
4.3 4.3. Sự Nảy sinh Chuỗi Suy luận Nội tại, Mở rộng lúc Suy diễn & Agentic RL (2025–2026)
4.4 4.4. Tổng kết Phần 4 (RLVR + GRPO): Thành tựu & Các Vấn đề Tồn đọng cho Phần 5

5. Phần 5: Chưng cất Tri thức, Không gian Tham số & Tổng kết Hệ thống

Hạn chế của Mạng Thưởng r_ϕ trong Suy luận

- **Thiên kiến hình thức bề mặt:** Mạng r_ϕ gán điểm cao cho lời giải trình bày LaTeX chặt chẽ dù biến đổi sai ở bước cuối.
- **Trục lợi phần thưởng trên chuỗi dài:** Khi chạy RL nhiều bước, π_θ sinh lập luận ngụy biện để đánh lừa r_ϕ thay vì giải đúng bài toán.

Cơ chế RLVR (RL with Verifiable Rewards)

- Trong miền hình thức (Toán học, Lập trình, Logic), **tính đúng đắn của nghiệm là khách quan và tất định**.
- Thay thế mạng r_ϕ bằng **Bộ Kiểm chứng Tất định**:
  - *Toán học:* Đối sánh đại số biểu thức trong \boxed{} với y_{gold}.
  - *Lập trình:* Biên dịch và thực thi bộ kiểm thử (Unit Tests).

Hàm Phần thưởng Nhị phân Tất định (Deterministic Verifiable Reward)

$$R_{\text{RLVR}}(x, y) = \begin{cases} 1 & \text{nếu } \text{Verify}\big(\text{ExtractAnswer}(y),\ y_{\text{gold}}\big) = \text{True} \\ 0 & \text{trong mọi trường hợp còn lại} \end{cases}$$

Đặc tính Giải tích của RLVR trong Tối ưu hóa Dài hạn

- **Bất biến với nhiễu bề mặt:** Bất kể độ dài hay văn phong lập luận, sai lệch kết quả cuối cùng hoặc trượt kiểm thử đều nhận $R_{\text{RLVR}} = 0$.
- **Không có sai số ngoại suy (Zero OOD Degradation):** Cho phép duy trì vòng lặp RL qua hàng chục nghìn bước cập nhật để khám phá chuỗi suy luận sâu (như OpenAI o1/o3, DeepSeek-R1).

Định vị Sai số trên Quỹ đạo Suy luận Đa bước $y = (s_1, s_2, \ldots, s_K)$

1. Mô hình Thưởng Kết quả (ORM)

- **Cơ chế:** Chỉ cấp một điểm thưởng duy nhất tại cuối chuỗi y.
- **Ưu điểm:** Không cần nhãn bước trung gian; tương thích trực tiếp với bộ kiểm chứng RLVR.
- **Hạn chế lý thuyết:** Tín hiệu thưa (*Sparse Reward*) — phạt đồng loạt mọi bước trong quỹ đạo sai.

2. Mô hình Thưởng Quá trình (PRM)

- **Cơ chế:** Cấp điểm thưởng r_k ngay sau từng bước biến đổi trung gian s_k.
- **Ưu điểm lý thuyết:** Tín hiệu dày đặc (*Dense Credit Assignment*) — bảo toàn các bước đầu đúng và định vị chính xác bước phát sinh lỗi.

Ba Rào cản Cấu trúc khiến Mạng PRM Suy thoái trong Huấn luyện RL Dài hạn

1. **Bất định ranh giới bước (Step Boundary Ambiguity):**
   Tư duy tự do (thử nghiệm, tự phản biện, quay lui) không thể phân tách cứng nhắc thành các bước đồng nhất.

2. **Chi phí gán nhãn quá trình đắt đỏ:**
   Bộ kiểm chứng tất định không chấm được bước nháp dở dang; huấn luyện mạng PRM đòi hỏi gán nhãn thủ công hoặc chạy tìm kiếm cây Monte Carlo (MCTS) tốn kém.

3. **Trục lợi phần thưởng cấp độ bước (Step-level Reward Hacking):**
   Do PRM vẫn là mạng xấp xỉ thần kinh, chính sách π_θ học cách chia lời giải thành hàng trăm bước biến đổi hiển nhiên ("$1 = 1 \implies 2 = 2$") để tích lũy điểm dương giả tạo.

Hai Giới hạn của PPO trên Chuỗi Suy luận Dài

1. **Chi phí bộ nhớ gấp đôi từ mạng Critic V_ψ:** Phải lưu trữ và cập nhật mạng V_ψ (70B–671B tham số) song song với π_θ.

2. **Phương sai cao của $V_\psi(s_t)$ dưới phần thưởng thưa:** Trong RLVR, điểm thưởng $\{0, 1\}$ chỉ xuất hiện ở token cuối thứ 10,000; việc ước lượng $V_\psi(s_t)$ tại token $t \ll T$ có sai số rất lớn, làm lệch lợi thế $\hat{A}_t$.

Giải pháp GRPO (Shao et al., 2024 – DeepSeekMath)

Nguyên lý: Khử hoàn toàn mạng Giá trị V_ψ.

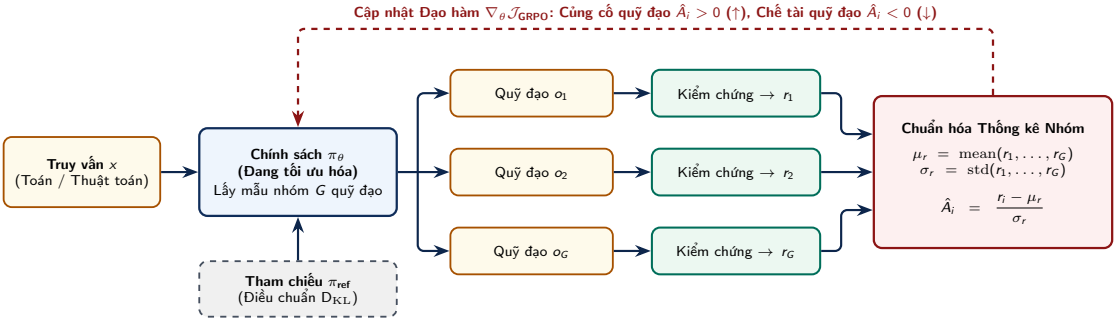
1. Với mỗi truy vấn x, lấy mẫu song song một nhóm G quỹ đạo $\{o_1, o_2, \ldots, o_G\} \sim \pi_{\theta_{\text{old}}}(\cdot \mid x)$.

2. Chấm điểm cả nhóm bằng bộ kiểm chứng RLVR: $\{r_1, r_2, \ldots, r_G\}$.

3. Dùng trung bình nhóm μ_r làm đường cơ sở $b(x)$ và chuẩn hóa Z-score theo σ_r.

Phần 4.2: Kiến trúc & Luồng Dữ liệu của Hệ thống RLVR + GRPO

Tối ưu hóa Chính sách thông qua Lấy mẫu Nhóm G Quỹ đạo mà Không cần Mạng Giá trị V_ψ



Công thức 8: Hàm Mục tiêu GRPO và Lợi thế Chuẩn hóa Tương đối $\hat{A}_i$

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E}_{x,\ \{o_i\}_{i=1}^{G} \sim \pi_{\theta_{\text{old}}}} \left[\frac{1}{G} \sum_{i=1}^{G} \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \left(\min\left(\rho_{i,t}\hat{A}_i,\ \text{clip}(\rho_{i,t}, 1-\epsilon, 1+\epsilon)\hat{A}_i\right) - \beta\, \mathrm{D}_{\text{KL}}(\pi_\theta \parallel \pi_{\text{ref}}) \right) \right]$$

Với lợi thế chuẩn hóa Z-score cho mọi token $t \in \{1, \ldots, |o_i|\}$:

$$\hat{A}_i = \frac{r_i - \text{mean}(r_1, r_2, \ldots, r_G)}{\text{std}(r_1, r_2, \ldots, r_G)}$$

Đặc tính Giải tích

- **Đồng nhất lợi thế cấp chuỗi ($\hat{A}_{i,t} \equiv \hat{A}_i$):** Mọi token thuộc quỹ đạo o_i chia sẻ chung trọng số lợi thế $\hat{A}_i$.
- **Tự thích nghi theo độ khó của x:** Phép chuẩn hóa Z-score giữ kỳ vọng $\mathbb{E}[\hat{A}_i] = 0$ và phương sai $\text{Var}(\hat{A}_i) = 1$ ổn định trên mọi bài toán.

Xét truy vấn toán học x với nhóm $G = 4$ quỹ đạo tự sinh $\{o_1, o_2, o_3, o_4\}$ ($\mu_r = 0.275, \sigma_r = 0.42$)

Quỹ đạo	Kết quả Kiểm chứng Tất định	Điểm r_i	Lợi thế $\hat{A}_i = \frac{r_i - 0.275}{0.42}$	Hướng Cập nhật Đạo hàm
Quỹ đạo o_1	Đáp số **Đúng** + Đúng thẻ `<think>`	$r_1 = 1.0$	$\hat{A}_1 = +1.72 > 0$	**Tăng mạnh xác suất ($\uparrow\uparrow$)**
Quỹ đạo o_2	Đáp số **Sai**, đúng thẻ `<think>`	$r_2 = 0.1$	$\hat{A}_2 = -0.41 < 0$	**Giảm nhẹ xác suất ($\downarrow$)**
Quỹ đạo o_3	Đáp số **Sai** + Sai cấu trúc	$r_3 = 0.0$	$\hat{A}_3 = -0.65 < 0$	**Giảm mạnh xác suất ($\downarrow\downarrow$)**
Quỹ đạo o_4	Đáp số **Sai** + Sai cấu trúc	$r_4 = 0.0$	$\hat{A}_4 = -0.65 < 0$	**Giảm mạnh xác suất ($\downarrow\downarrow$)**

Nhận xét Định lượng

Không cần mạng Giá trị V_ψ, chuẩn hóa nhóm tự động gán lợi thế dương cho quỹ đạo đúng duy nhất (o_1) và đẩy các quỹ đạo sai xuống miền lợi thế âm.

1. Thiên kiến Độ dài ⟶ Dr. GRPO (Liu et al., 2025)

- **Khiếm khuyết của GRPO gốc:** Chia tổng lợi thế cho độ dài chuỗi $\frac{1}{|o_i|}$ trong Công thức 8.
- **Hệ quả:** Với mẫu âm ($\hat{A}_i < 0$), chuỗi sai càng dài ($|o_i|$ lớn) thì mức phạt trung bình trên mỗi token càng nhẹ $\implies$ mô hình kéo dài câu trả lời sai.
- **Hiệu chỉnh Dr. GRPO:** Bỏ hệ số chia $\frac{1}{|o_i|}$ và σ_r, giữ estimator đạo hàm không chệch.

2. Sụp đổ Entropy ⟶ DAPO (Yu et al., 2025)

- **Hạn chế cắt tỉa đối xứng $[1-\epsilon, 1+\epsilon]$:** Với $\epsilon = 0.2$, token khám phá mới ($\pi_{\text{old}} = 0.01$) bị chặn trên tại 0.012, kìm hãm đa dạng suy luận.
- **Hiệu chỉnh Clip-Higher (DAPO):** Tách cận cắt tỉa bất đối xứng $[1-\epsilon_{\text{low}},\ 1+\epsilon_{\text{high}}]$ với $\epsilon_{\text{high}} > \epsilon_{\text{low}}$ để duy trì entropy khám phá.

Thiết kế Phần thưởng Tối giản

Chạy GRPO trực tiếp trên Base Model (không qua SFT), chỉ dùng **2 quy tắc kiểm chứng**:

1. **Phần thưởng Độ chính xác (r_{acc}):** Kiểm tra tính tương đương đại số của đáp số cuối.
2. **Phần thưởng Định dạng (r_{format}):** Kiểm tra cấu trúc thẻ `<think>...</think>` và `<answer>...</answer>`.

Chú ý: Không có bất kỳ hàm thưởng nào quy định nội dung hay độ dài bên trong thẻ `<think>`.

Cơ chế Tự Hình thành Tư duy Hệ thống 2

- Các quỹ đạo tự phân bổ nhiều token trong `<think>` để **phân rã bài toán, kiểm định giả thuyết và tự sửa lỗi** đạt xác suất giải đúng ($r_{\text{acc}} = 1$) vượt trội.
- Qua chọn lọc tự nhiên của $\hat{A}_i > 0$, chính sách tự củng cố hành vi siêu nhận thức (*Metacognitive Self-Correction*).
- Chuyển dịch từ **Phản xạ Hệ thống 1** sang **Suy luận Hệ thống 2**.

1. Mở rộng Lúc Suy diễn (Snell et al., 2024)

Hiệu năng suy luận tăng theo ngân sách tính toán lúc giải mã trên 2 trục trực giao:

- **Mở rộng Nối tiếp (Sequential Scaling):**
  Kéo dài chuỗi `<think>` để tự kiểm tra và hiệu chỉnh sai số trên một quỹ đạo.
- **Mở rộng Song song (Parallel Scaling):**
  Lấy mẫu N quỹ đạo độc lập, hợp nhất bằng **Self-Consistency (Majority Voting)** hoặc **Best-of-N**.

2. Xu hướng 2025–2026: Agentic & Rubric RL

- **Agentic RL Đa vòng (Multi-turn Tool-Use RL):**
  Nhúng GRPO vào môi trường thực thi: suy nghĩ `<think>` $\rightarrow$ gọi công cụ (Terminal, Compiler, Search) $\rightarrow$ nhận phản hồi môi trường $\rightarrow$ suy luận tiếp.
- **Rubric-based RL & GenRM:**
  Mở rộng RLVR sang tác vụ mở bằng bộ tiêu chí kiểm chứng phân rã (Checklists) và mô hình thưởng có suy luận (*Generative Reward Model*).

Những gì RLVR + GRPO Đã Giải quyết & Tối ưu hơn so với Phần 2 và Phần 3

Tiêu chí Đánh giá	PPO (Phần 2) & DPO (Phần 3)	RLVR + GRPO (Phần 4 – 2024–2026)
1. Tín hiệu định giá	Mạng r_ϕ hoặc cặp tĩnh (bị *Reward Hacking* trên Toán/Code)	**Bộ kiểm chứng tất định (RLVR)**: Khách quan tuyệt đối, triệt tiêu gian lận hình thức
2. Ước lượng đường cơ sở	PPO cần mạng Critic V_ψ lớn, sai số cao trên chuỗi dài	**Chuẩn hóa nhóm G quỹ đạo (GRPO)**: Khử hoàn toàn mạng Critic V_ψ, giảm 50% VRAM
3. Năng lực suy luận	Phản xạ Hệ thống 1 (học tĩnh trên dữ liệu sẵn có)	**Tư duy Hệ thống 2 (`<think>`)**: Tự khám phá trực tuyến và mở rộng tính toán lúc chạy

Ba Rào cản Khi Chạy Trực tiếp RLVR + GRPO trên Mô hình Dung lượng Nhỏ (1.5B–14B)

1. **Điều kiện Cần của Giải thuật GRPO ($\sigma_r > 0$):**
   Trong nhóm G quỹ đạo $\{o_1, \ldots, o_G\}$, bắt buộc phải xuất hiện ít nhất một vài mẫu dương giải đúng để tạo độ lệch chuẩn $\sigma_r > 0$.

2. **Hiện tượng Cạn kiệt Phần thưởng & Triệt tiêu Đạo hàm ($\nabla_\theta \mathcal{J} = 0$):**
   Trước bài toán khó, mô hình nhỏ (1.5B–14B) giải sai cả $G = 64$ lần thử
   ($r_1 = \cdots = r_G = 0 \implies \hat{A}_i = 0 \implies \nabla_\theta \mathcal{J} = 0$). Quá trình học hoàn toàn bất động!

3. **Chi phí Tính toán của Khám phá RL từ Đầu:**
   Chỉ khả thi trên mô hình Frontier dung lượng lớn (như 671B).

Bài toán Chuyển giao sang Phần 5 (Chưng cất Tri thức – Knowledge Distillation)

Sử dụng mô hình Frontier đã qua RL làm **Mô hình Thầy (π_T)** để truyền thẳng phân phối dự đoán $P_T^{(\tau)}$ và quỹ đạo suy luận `<think>` sang **Mô hình Trò (π_S)**.

Mục lục Tiến trình Seminar (2020–2026)

Cấu trúc Học thuật & Vị trí Phần Hiện tại

1. Phần 1 (2020–2021): Từ Tiền huấn luyện đến Tinh chỉnh có Giám sát (SFT)

2. Phần 2 (2022–Đầu 2023): Căn chỉnh Mô hình bằng Học Tăng cường (RLHF & PPO)

3. Phần 3 (2023–2024): Tối ưu hóa Chính sách Trực tiếp (DPO & Các Biến thể)

4. Phần 4 (Cuối 2024–2026): Học Tăng cường Kiểm chứng & Suy luận (RLVR & GRPO)

5. Phần 5: Chưng cất Tri thức, Không gian Tham số & Tổng kết Hệ thống

5.1 5.1. Chưng cất Tri thức từ Mô hình Thầy Frontier sang Mô hình Trò Nhỏ (Distillation)

5.2 5.2. Thích nghi Hạng Thấp (LoRA), Hợp nhất Tham số & Đánh giá Hệ thống

5.3 5.3. Tổng kết Toàn diện Chuyên đề Seminar (2020–2026)

1. Khuôn khổ Học Thầy–Trò (Hinton et al., 2015; Kim & Rush, 2016)

Chuyển giao phân phối xác suất và quỹ đạo suy luận từ **Mô hình Thầy Frontier (π_T)** đã qua huấn luyện RL quy mô lớn sang **Mô hình Trò (π_S)** có dung lượng tham số nhỏ.

2. Ba Phương thức Biểu diễn Tri thức Chuyển giao

1. **Chưng cất Phân phối Dự đoán (Logit / White-box KD):**
   Đối khớp phân phối xác suất mềm $P_T^{(\tau)}(\cdot \mid s_t)$ trên toàn bộ từ điển $\mathcal{V}$ tại từng token.

2. **Chưng cất Chuỗi Đầu ra (Sequence-Level / Black-box KD):**
   Tối đa hóa hợp lý logarit trên phản hồi hoàn chỉnh $y_T \sim \pi_T(\cdot \mid x)$.

3. **Chưng cất Quỹ đạo Suy luận (Rationale / Reasoning KD):**
   Chuyển giao đồng thời chuỗi lập luận trung gian `<think>` z_T đã kiểm chứng và kết luận y_T.

Thí nghiệm Đối chứng: Tự Chạy GRPO từ Đầu so với Chưng cất từ Thầy 671B

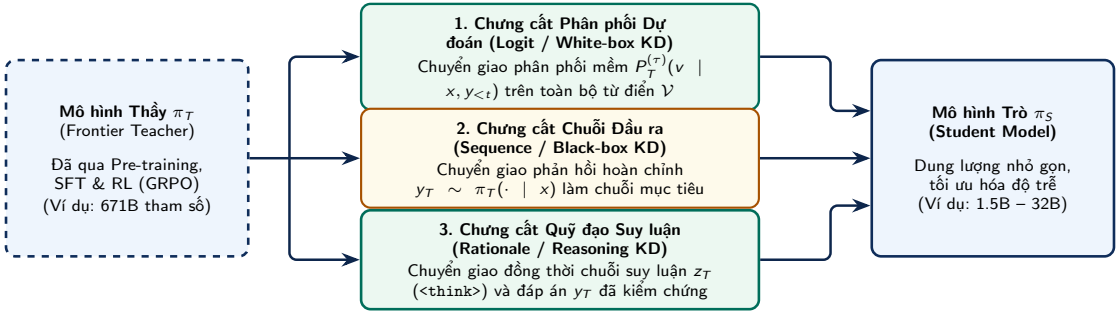
Phương thức Huấn luyện trên Qwen-32B	**AIME 2024**	**MATH-500**	**Giải thích Cơ chế Lý thuyết**
1. Tự chạy RL từ đầu (Zero-RL / GRPO $>$ 10,000 bước)	47.0%	83.9%	Bị giới hạn bởi dung lượng khám phá tiên nghiệm của mạng 32B
2. Chưng cất Suy luận từ Thầy DeepSeek-R1 671B	**72.6%**	**94.3%**	**Vượt trội** +25.6% nhờ kế thừa trực tiếp quỹ đạo suy luận của Thầy 671B

Phân công Chiến lược trong Hệ sinh thái Hậu Huấn luyện

Dùng **Online RL (RLVR + GRPO)** trên mô hình Frontier để **khám phá tri thức suy luận mới**; dùng **Chưng cất Quỹ đạo Suy luận** để nén năng lực đó xuống mô hình nhỏ.

Phần 5.1: Kiến trúc & Luồng Dữ liệu của Ba Phương thức Chưng cất Tri thức

So sánh Luồng Tín hiệu Huấn luyện giữa Chưng cất Hộp Trắng (White-box) và Hộp Đen (Black-box)



Điều kiện kỹ thuật: Phương thức 1 đòi hỏi cùng bộ từ vựng $\mathcal{V}$ và truy cập vector logit (*White-box*); Phương thức 2 & 3 chỉ dùng văn bản đầu ra nên áp dụng được cho mọi cặp mô hình (*Black-box*).

Công thức 9: Phân phối Softmax Nhiệt độ τ và Hàm Mục tiêu Logit KD

$$P^{(\tau)}(v_k \mid s_t) = \frac{\exp(z_k/\tau)}{\sum_{j=1}^{|\mathcal{V}|}\exp(z_j/\tau)}, \qquad \mathcal{L}_{\text{Logit-KD}}(\theta_S) = \tau^2\, \mathrm{D}_{\mathrm{KL}}\left(P_T^{(\tau)}(\cdot \mid s_t) \,\middle\|\, P_S^{(\tau)}(\cdot \mid s_t)\right)$$

Cấu trúc Tương quan Ngữ nghĩa (Dark Knowledge)

- Nhãn cứng (One-hot) chỉ gán xác suất 1 cho 1 từ và 0 cho $|\mathcal{V}| - 1$ từ còn lại.
- Phân phối mềm $P_T^{(\tau)}$ (ví dụ: *"mèo"*: 0.70, *"chó"*: 0.25, *"tủ lạnh"*: 10^{-8}) truyền tải **cấu trúc hình học tương đồng giữa các khái niệm**.

Vai trò của Nhiệt độ $\tau > 1$ và Hệ số τ^2

- **Chia cho $\tau > 1$:** Làm phẳng phân phối Softmax, nâng xác suất vùng đuôi để Trò tiếp nhận rõ cấu trúc tương quan.
- **Nhân với τ^2:** Bù lại sự suy giảm biên độ đạo hàm $\nabla_{z_S} \mathrm{D}_{\mathrm{KL}} \propto 1/\tau^2$.

Hàm Mục tiêu Chưng cất Quỹ đạo Suy luận (Rationale Distillation – Hsieh et al., 2023)

$$\mathcal{L}_{\text{Rationale-KD}}(\theta_S) = -\mathbb{E}_{(x,z_T,y_T)\sim\mathcal{D}_{\text{verified}}}\Big[\log \pi_S(z_T \mid x) + \log \pi_S(y_T \mid x, z_T)\Big]$$

Hạn chế của Sequence KD ($x \mapsto y_T$)

- Đáp án cuối y_T là kết quả của nhiều bước biến đổi ẩn bên trong mạng Thầy lớn.
- Lược bỏ chuỗi suy luận trung gian z_T khiến Mô hình Trò (ít tầng ẩn hơn) rơi vào trạng thái **khớp mẫu bề mặt (Surface Pattern Matching)**.

Ưu thế của Rationale KD ($x \mapsto z_T \mapsto y_T$)

- Lọc mẫu theo ngưỡng kiểm chứng (*Rejection Sampling*) để giữ các cặp (z_T, y_T) đúng của Thầy.
- Sinh chuỗi <think> z_T trước giúp phân rã bài toán khó thành chuỗi các bước dự đoán cục bộ đơn giản trên ngữ cảnh.

Công thức 10: Hai Chiều Phân kỳ KL giữa Mô hình Thầy (P_T) và Mô hình Trò (P_S)

1. Forward KL: $\mathrm{D}_{\mathrm{KL}}(P_T \parallel P_S) = \sum_y P_T(y) \log \frac{P_T(y)}{P_S(y)}$ **2. Reverse KL:** $\mathrm{D}_{\mathrm{KL}}(P_S \parallel P_T) = \sum_y P_S(y)$

Forward KL: Phủ Trung bình (Mean-Seeking)

- Khi $P_T(y) > 0$, bắt buộc $P_S(y) > 0$ (nếu $P_S \to 0 \implies \log \frac{P_T}{P_S} \to +\infty$).
- Mô hình Trò nhỏ cố trải rộng phân phối bao phủ mọi đỉnh của Thầy $\implies$ trọng tâm rơi vào vùng mật độ thấp ở giữa (nơi $P_T(y) \approx 0$).

Reverse KL: Hội tụ Cực đại (Mode-Seeking)

- Khi $P_T(y) = 0$, bắt buộc $P_S(y) = 0$. Nhưng nếu Trò bỏ qua một số đỉnh phụ của Thầy ($P_S(y) = 0$), tích số $0 \log 0 = 0$ không gây phạt.
- Cho phép Trò **tập trung** 100% **dung lượng vào một cực đại tốt nhất của Thầy**.

Quy trình Hai Pha Khắc phục Đồng thời Triệt tiêu Đạo hàm và Exposure Bias

1. **Pha 1 – Chưng cất từ Mô hình Thầy Frontier (Logit KD / Rationale KD):**
   Khởi tạo năng lực suy luận cho mô hình nhỏ, nâng xác suất giải đúng tiên nghiệm từ 0% lên 50%–70%. Tuy nhiên, do học tĩnh trên chuỗi của Thầy, mô hình Trò vẫn chịu *Exposure Bias* và thiếu tín hiệu từ mẫu âm của chính nó.

2. **Pha 2 – Chạy Bồi GRPO (RLVR) và DPO Trực tiếp trên Mô hình Trò:**
   Nhờ Pha 1, nhóm G quỹ đạo lấy mẫu trên mô hình nhỏ đã có cả mẫu dương lẫn mẫu âm ($\sigma_r > 0 \implies \hat{A}_i \neq 0$). Chạy tiếp GRPO + DPO giúp mô hình nhỏ tự khử lỗi lập luận nội tại và vượt trần chưng cất tĩnh (ứng dụng trên *Qwen3, Gemma 2/3, DeepScaleR*).

1. Chiều Nội tại Thấp & LoRA (Hu et al., 2022)

$$W = W_0 + \Delta W = W_0 + \frac{\alpha}{r} BA, \quad r \ll \min(d, k)$$

- **Chiều nội tại thấp (Aghajanyan et al.):** Độ lệch ΔW trong Post-Training nằm trên đa tạp con hạng r rất nhỏ ($r \in \{16, 32\}$).
- **Chống Quên Thảm khốc (Biderman et al., 2024):** Đóng băng W_0 và chỉ cập nhật $< 1\%$ tham số giúp bảo toàn tri thức gốc của Base Model.

2. Số học Vector Tác vụ & Hợp nhất Mô hình

$$\tau_i = \theta^{(i)}_{\text{finetuned}} - \theta_{\text{base}} \implies \theta_{\text{merged}} = \theta_{\text{base}} + \sum_{i=1}^{M} \lambda_i \tau_i$$

- **Linear Mode Connectivity:** Các mô hình tinh chỉnh từ cùng θ_{base} nằm chung trong một vùng trũng hàm mất mát (Loss Basin).
- **TIES-Merging & DARE:** Cắt tỉa 90% biến thiên nhỏ và đồng bộ dấu để hợp nhất kỹ năng *Toán* (τ_{math}) và *Hội thoại* (τ_{chat}).

1. Thuế Căn chỉnh & Hệ thống Elo

- **Thuế Căn chỉnh (Alignment Tax):**
  Quá trình RLHF / DPO thu hẹp entropy phân phối, làm giảm nhẹ độ đa dạng hoặc độ hiệu chỉnh xác suất (Calibration).
- **Định lượng Elo (Chatbot Arena):**
  Đánh giá đối kháng mù từng cặp theo mô hình Bradley-Terry:

$$P(A \succ B) = \frac{1}{1 + 10^{(R_B - R_A)/400}}$$

2. Ba Thiên kiến của Trọng tài AI (LLM-as-a-Judge)

Thiên kiến	Phương pháp Hiệu chỉnh Thống kê
1. Vị trí (*Position*)	Đánh giá 2 chiều hoán vị (A, B) và (B, A)
2. Độ dài (*Verbosity*)	Hồi quy tách phương sai độ dài (*Length-Controlled Win Rate*)
3. Tự tương đồng	Hội đồng đa mô hình hoặc bộ kiểm chứng tất định

Phần 5.3: Hệ thống Phân loại Học thuật Ba Tầng trong Hậu Huấn luyện

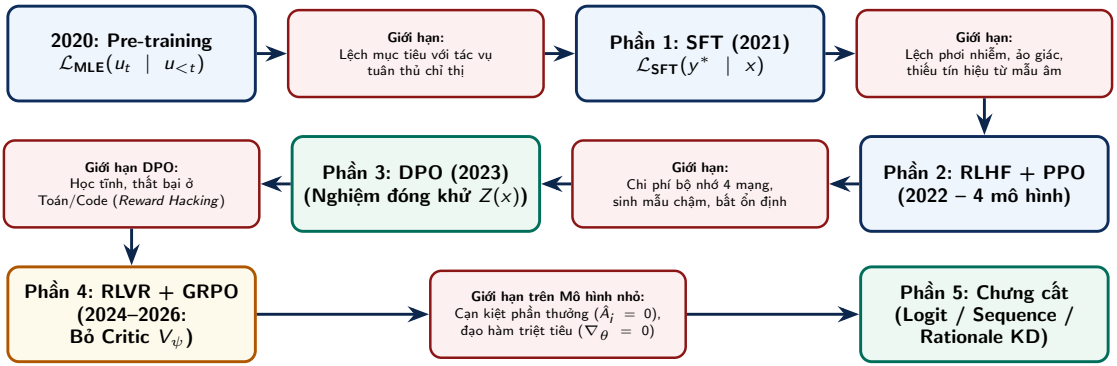
Tách biệt Rạch ròi giữa Nguồn Phản hồi, Độ mịn Gán Tín dụng và Giải thuật Tối ưu hóa

TẦNG 1: Nguồn Phát Tín hiệu Phản hồi (Feedback Source)	**RLHF (Phần 2)** Đánh giá từ Con người (Cặp đối chiếu $y_w \succ y_l$)	**RLAIF (Phần 3)** Đánh giá từ Mô hình AI (Hiến pháp / Quy tắc)	**RLVR (Phần 4)** Bộ Kiểm chứng Tất định (Toán học / Trình biên dịch)
TẦNG 2: Độ Mịn Gán Tín dụng (Credit Granularity)	**ORM (Outcome Reward Model)** Cấp phát phần thưởng duy nhất ở cuối chuỗi phản hồi		**PRM (Process Reward Model)** Cấp phát phần thưởng chi tiết sau từng bước suy luận trung gian
TẦNG 3: Giải thuật Tối ưu hóa Tham số (Optimization Algorithm)	**PPO (Phần 2)** RL trực tuyến có mạng Giá trị V_ψ (Hệ thống 4 mô hình)	**DPO / SimPO (Phần 3)** Tối ưu hóa trực tiếp từ cặp tĩnh (Nghiệm đóng hàm mục tiêu)	**GRPO (Phần 4)** RL trực tuyến chuẩn hóa nhóm G (Loại bỏ mạng Giá trị)

Tổ hợp kiến trúc điển hình theo lịch sử: *InstructGPT (2022)* = **RLHF** + **ORM** + **PPO**. | *DeepSeek-R1 (2025)* = **RLVR** + **ORM** + **GRPO**.

Phần 5.3: Sơ đồ Tổng hợp Chuỗi Tiến hóa Lý thuyết (2020–2026)

Mạch Logic Nhân quả: Giới hạn của Phương pháp Tiền nhiệm ⟶ Động cơ của Phương pháp Kế tiếp



Quy trình tích hợp hiện đại: SFT khởi tạo ⟶ RLVR + GRPO khám phá suy luận trên Frontier ⟶ DPO căn chỉnh đa mục tiêu ⟶ Distillation nén xuống mô hình nhỏ.

Phần 5.3: Bảng Tổng hợp Đối chiếu Năm Phần Trụ cột theo Trình tự Lịch sử

Tóm tắt Thành tựu Đạt được, Cấu hình Hệ thống và Điểm Nghẽn Chuyển giao qua Từng Giai đoạn

Giai đoạn / Phần	Tín hiệu Học	Số Mô hình	Thành tựu Tối ưu so với Trước đó	Vấn đề Để lại cho Phần Sau
Phần 1: SFT (2020–2021)	Mẫu dương chuẩn (x, y^*)	**1 mạng:** π_θ	Giải quyết *Objective Mismatch*, dạy khuôn mẫu hội thoại nhanh	*Exposure Bias*, kích thích ảo giác, thiếu tín hiệu từ mẫu âm
Phần 2: RLHF+PPO (2022 – ChatGPT)	Điểm thưởng $r_\phi(x, \hat{y})$ trên mẫu tự sinh	**4 mạng:** $\pi_\theta, \pi_{\text{ref}}, r_\phi, V_\psi$	Học trực tuyến (*On-policy*), đạo hàm 2 chiều chế tài mẫu âm	Tốn bộ nhớ gấp 4 lần, sinh mẫu chậm, đạo hàm RL bất ổn định
Phần 3: DPO (2023–2024)	Cặp mẫu dương/âm $(x, y_w \succ y_l)$	**2 mạng:** $\pi_\theta, \pi_{\text{ref}}$	Nghiệm đóng khử $Z(x)$, bỏ r_ϕ & V_ψ, ổn định như SFT	Học tĩnh (*Off-policy*), thất bại ở Toán/Code do *Reward Hacking*
Phần 4: RLVR+GRPO (Cuối 2024–2026)	Bộ kiểm chứng trên nhóm $\{o_1..o_G\}$	**2 mạng:** $\pi_\theta, \pi_{\text{ref}}$ (+ Verifier)	Bỏ Critic V_ψ, miễn nhiễm *Reward Hacking*, nảy sinh `<think>`	Mô hình nhỏ bị cạn kiệt phần thưởng ($\hat{A}_i = 0 \implies \nabla_\theta = 0$)
Phần 5: Chưng cất (Distillation)	Phân phối $P_T^{(\tau)}$ hoặc chuỗi (z_T, y_T)	**2 mạng:** Thầy $\pi_T \to$ Trò π_S	Truyền thẳng suy luận từ Thầy Frontier xuống mô hình nhỏ	Kết hợp thêm GRPO/DPO nhẹ sau chưng cất để khử *Exposure Bias*

Các Kết luận Khoa học Cốt lõi

1. **Phần 1 (2020–2021 – SFT):** Định hình phân phối tuân thủ chỉ thị $\pi_\theta(y^* \mid x)$, nhưng chịu giới hạn bởi *Exposure Bias* và sự vắng mặt của tín hiệu phạt từ mẫu âm.
2. **Phần 2 (2022 – RLHF & PPO):** Kết hợp hàm thưởng Bradley-Terry $r_\phi(y_w \succ y_l)$, điều chuẩn vùng tin cậy $\beta\, \mathrm{D}_{\mathrm{KL}}$ và giải thuật PPO giúp căn chỉnh trực tuyến, nhưng chịu gánh nặng bộ nhớ 4 mô hình.
3. **Phần 3 (2023–2024 – DPO):** Nghiệm đóng phân phối Gibbs–Boltzmann kết hợp tính bất biến tịnh tiến Bradley-Terry giúp khử hàm phân hoạch $\beta \log Z(x)$, tối ưu hóa trực tiếp trên cặp mẫu dương/âm (y_w, y_l).
4. **Phần 4 (Cuối 2024–2026 – RLVR & GRPO):** Bộ kiểm chứng tất định kết hợp chuẩn hóa nhóm G quỹ đạo giúp xóa bỏ mạng Giá trị V_ψ và kích hoạt chuỗi suy luận nội tại Hệ thống 2 (`<think>`).
5. **Phần 5 (Chưng cất Tri thức & Không gian Tham số):** Chưng cất quỹ đạo suy luận kết hợp phân kỳ KL ngược (*Reverse KL*) giúp mô hình nhỏ vượt qua hiện tượng triệt tiêu đạo hàm của RL.

Trân trọng cảm ơn sự theo dõi của Quý Thầy Cô và các bạn! — Thảo luận & Hỏi Đáp (Q&A)